arXiv:2010.08895v3 [cs. LG] 2021年5月17日

傅里叶神经算子
参数型偏微分方程

李宗义 zongyili@caltech.edu
尼古拉·科瓦奇基 nkovachki@caltech.edu
卡米亚尔·阿齐兹达内谢利 kamyar@purdue.edu
刘伯吉德 bgl@caltech.edu
考希克·巴塔查里亚 bhatta@caltech.edu
安德鲁·斯图尔特 astuart@caltech.edu
安妮玛·阿南德库马尔 anima@caltech.edu

摘要

传统神经网络的发展主要聚焦于学习有限维欧几里得空间之间的映射关系。近年来，这一方法被推广至神经算子领域——即通过神经网络学习函数空间之间的映射关系。对于偏微分方程（PDEs）而言，神经算子可直接学习从任意泛函参数依赖关系到解之间的映射关系；因此，它们能够学习整个偏微分方程族，而传统方法仅针对单个方程进行求解。在本研究中，我们通过直接在傅里叶空间对积分核进行参数化，构建了一种新型神经算子，从而实现了具有强表达能力和高效性的网络架构。我们针对 Burgers 方程、Darcy 流以及 Navier-Stokes 方程开展了实验验证。该傅里叶神经算子是首个基于机器学习、并能实现零样本超分辨率湍流流场建模的方法；其计算速度比传统偏微分方程求解器快达三个数量级。此外，在固定分辨率条件下，该方法相较于以往基于学习的求解器具有更优的精度。

1 引言

在科学与工程领域，许多问题涉及针对不同参数取值反复求解复杂的偏微分方程（PDE）系统。这类问题常见于分子动力学、微观力学及湍流流动等领域。通常，此类系统需要进行精细的离散化处理，才能准确捕捉所建模的物理现象；因此，传统的数值求解方法计算速度较慢，且有时效率不高。例如，在设计诸如翼型等材料时，需求解相关的逆问题，而该问题往往需要对正向模型进行数千次计算；采用快速求解方法可使这类问题变得切实可行。

传统求解器与数据驱动方法对比。传统的求解器（如有限元法（FEM）和有限差分法（FDM））通过对空间进行离散化来求解方程；因此，它们在分辨率上存在权衡：粗网格计算速度快但精度较低；而细网格计算精度高但速度较慢。如上所述，复杂的偏微分方程（PDE）系统通常需要进行非常精细的离散化处理，因此对传统求解器而言极具挑战性且计算成本高昂；而数据驱动方法则可以直接从数据中学习该方程族的解轨迹。因此，基于学习的方法比传统求解器的运行速度可快数个数量级。

机器学习方法或许蕴含着革新科学学科的关键——通过提供能够近似或增强传统求解方法的快速求解器（Raissi 等，2019；Jiang 等，2020；Greenfeld 等，2019；Kochkov 等，2021）。然而，经典神经网络是在有限维空间之间进行映射的，因此只能学习与特定离散化方式相关的解。这一局限性在实际应用中往往成为制约因素，因此有必要开发具有网格不变性的神经网络。我们首先概述两种主流的基于神经网络的偏微分方程求解方法——有限维算子法与神经有限元法。

有限维算子。这些方法将解算子参数化为一个连接于有限维欧几里得空间之间的深度卷积神经网络Guo 等（2016）；Zhu

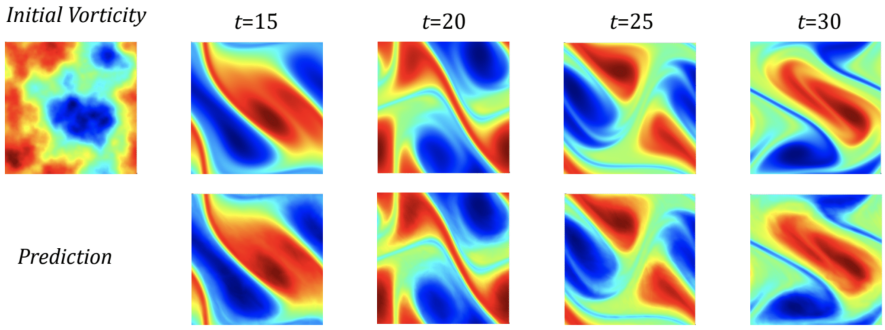

零样本超分辨率：Navier-Stokes 方程（黏度v= 1e-4）；上图为真实图像，下图为预测结果；在 64 × 64 × 20 的数据集上训练；在 256 × 256 × 80 的数据集上进行评估（参见第5.4节）。

图 1：**上图：**傅里叶层的架构；**下图：**基于 Navier-Stokes 方程的示例流场。

Zabaras（2018）；Adler 与 Oktem（2017）；Bhatnagar 等（2019）；Khoo 等（2017）。这些方法本质上依赖于网格划分，因此需要针对不同的分辨率和离散化方式进行调整与优化，以实现一致的误差（若可行的话）。此外，这些方法受限于训练数据的离散化尺寸和几何结构，因而无法在域内的新点处查询解。相比之下，我们证明了所提方法既具有误差对网格分辨率的不变性，又具备在不同网格之间迁移解的能力。

神经有限元法（Neural-FEM）。第二种方法将求解函数直接参数化为一个神经网络（E & Yu，2018；Raissi 等，2019；Bar & Sochen，2019；Smith 等，2020；Pan & Duraisamy，2020）。该方法旨在对偏微分方程的一个特定实例进行建模，而非对求解算子进行建模。该方法与网格无关且精度较高，但对于任何给定的新函数参数/系数实例，均需训练一个新的神经网络。该方法与有限元法等经典方法极为相似——它用神经网络空间替代了有限局部基函数集的线性空间。Neural-FEM 方法存在与经典方法相同的计算问题：需为每个新实例求解一次优化问题。此外，该方法仅适用于底层偏微分方程已知的场景。

神经算子。最近，一项新研究方向提出利用神经网络来学习无网格、无限维算子（Lu 等。）。，2019；Bhattacharya 等，2020；Nelsen 与Stuart，2020；Li 等，2020b；a；Patel 等，2021）。神经算子通过生成一组可适用于不同离散化方式的单一网络参数集，解决了上述有限维算子方法中存在的网格依赖性问题；它具备在不同网格间传递解的能力。此外，神经算子仅需训练一次；针对新参数实例求解解时，仅需对网络进行一次前向传播，从而缓解了神经有限元方法中存在的主要计算复杂度问题。最后，神经算子无需了解底层偏微分方程的信息，仅需输入数据即可。迄今为止，由于求解积分算子的计算成本较高，神经算子尚未能催生出与卷积或循环神经网络在有限维场景下取得的成功相媲美的高效数值算法。本研究通过快速傅里叶变换解决了这一问题。

傅里叶变换。傅里叶变换常用于求解微分方程的谱方法中，因为微分运算在傅里叶域中等价于乘法运算。傅里叶变换在深度学习的发展中也发挥了重要作用。在理论上，它出现在通用逼近定理的证明中（Hornik 等，1989）；在实践中，它被用于加速卷积神经网络的运算（Mathieu 等，2013）。此外，一些涉及傅里叶变换或使用正弦激活函数的神经网络架构也已被提出并加以研究（Bengio 等，2007；Mingo 等，2004；Sitzmann等，2020）。近期，一些适用于偏微分方程的谱方法已被扩展到神经网络领域（Fan等，2019a；b；Kashinath 等，2020）。我们在这些研究基础上，提出一种直接在傅里叶空间中定义的神经算子架构，该架构具有拟线性时间复杂度和最先进的近似能力。

我们的贡献。我们引入了“傅里叶神经算子”——一种新型深度学习架构，能够学习无限维函数空间之间的映射关系；该积分算子被限定为卷积运算，并通过傅里叶域中的线性变换来实现。

- 傅里叶神经算子是首个针对湍流区域中Navier-Stokes方程族学习分辨率不变解算子的研究成果；而在该领域，此前基于图结构的神经算子均未能收敛。
- 该方法在设计上共享相同的已学习网络参数，无论输入空间与输出空间采用何种离散化方式。它支持零样本超分辨率处理：即在较低分辨率数据集上进行训练后，直接在较高分辨率数据集上进行评估，如图1所示。
- 所提方法在所有现有深度学习方法中均表现最优——即使将分辨率固定为 64 × 64 时亦然。该方法在 Burgers 方程上的误差率降低了 30%，在 Darcy 流问题上降低了 60%，在 Navier-Stokes 方程（粘性系数ν= 1e—4 的湍流工况）上降低了 30%。在学习整个时间序列的映射时，该方法在黏性系数ν= 1e—3 时误差小于 1%，在黏性系数ν= 1e—4 时误差为 8%。
- 在× 256 的网格上，傅里叶神经算子的推理时间仅为 0.005 秒，而用于求解 Navier-Stokes 方程的伪谱方法所需时间为 2.2 秒。尽管该方法具有显著的速度优势，但在应用于求解贝叶斯逆问题等下游应用时，其计算精度并未下降，如图6所示。

我们观察到，所提出的框架能够近似求解具有高度非线性、包含高频率模态及缓慢能量衰减特征的偏微分方程中出现的复杂算子。神经算子的优势在于将线性全局积分算子（通过傅里叶变换实现）与非线性局部激活函数相结合。与标准神经网络通过将线性乘法运算与非线性激活函数相结合来近似高度非线性函数的方式类似，所提出的神经算子亦可用于近似高度非线性算子。

2 学习算子

我们的方法论通过一个有限的观测输入-输出对集合来学习两个无限维空间之间的映射关系。设$D \subset \mathbb{R}^{d_a}$为一个有界开集，且$A=A(D;\ \mathbb{R}^{d_a})$与$U=U(D;\ \mathbb{R}^{d_u})$分别为取值于$\mathbb{R}^{d_a}$和$\mathbb{R}^{d_u}$的函数所构成的可分巴拿赫空间。此外，设$G^\dagger: A \to U$为一个（通常）非线性映射。我们研究那些作为参数化偏微分方程解算子出现的映射$G^\dagger$——具体示例参见第5节。假设我们拥有观测数据集 $\{a_j, u_j\}_{j=1}^N$ where $a_j \sim \mu$是一个来自概率测度μ的独立同分布序列，该测度的支撑集为A；且$u_j = G^\dagger(a_j)$ 可能受到噪声干扰。我们旨在通过构建一个参数化映射来近似表示$G^\dagger$。

$$G \in A \times \Theta \to U，或等价地，G_\theta : A \to U，\theta \in \Theta \qquad (1)$$

对于某个有限维参数空间 Θ，通过选择 $\theta^\dagger \in \Theta$ 使得$G(\cdot,\ \theta^\dagger) = G_{\theta^\dagger \approx G}^\dagger$。这一框架是适用于无限维空间中学习问题的自然选择，因为我们可以定义一个成本泛函$C: U \times U \to \mathbb{R}$，并寻求该问题的最小化解。

$$\min_{\theta \in \Theta} \mathbb{E}_{a \sim \mu}[C(G(a,\ \theta),\ G^\dagger(a))]$$

这与经典有限维情形（Vapnik，1998）直接对应。在无限维情形下证明极小化点的存在性仍是一个具有挑战性的开放性问题。我们将在测试-训练框架下研究这一问题，即采用一种数据驱动的经验近似方法来处理用于确定 θ 以及检验该近似方法准确性的成本函数。由于我们将研究方法构建在无限维空间框架下，因此所有有限维近似均共享一组在无限维情形下保持一致的参数。相关符号表见附录3。

学习算子。对算子$G^\dagger$进行近似，是一项与求解针对单个参数实例$a \in A$的偏微分方程$u \in U$的问题截然不同且通常更具挑战性的任务。现有的大多数方法涵盖范围广泛，从经典的有限元法、有限差分法和有限体积法，到现代机器学习方法（例如基于物理信息的神经网络）。

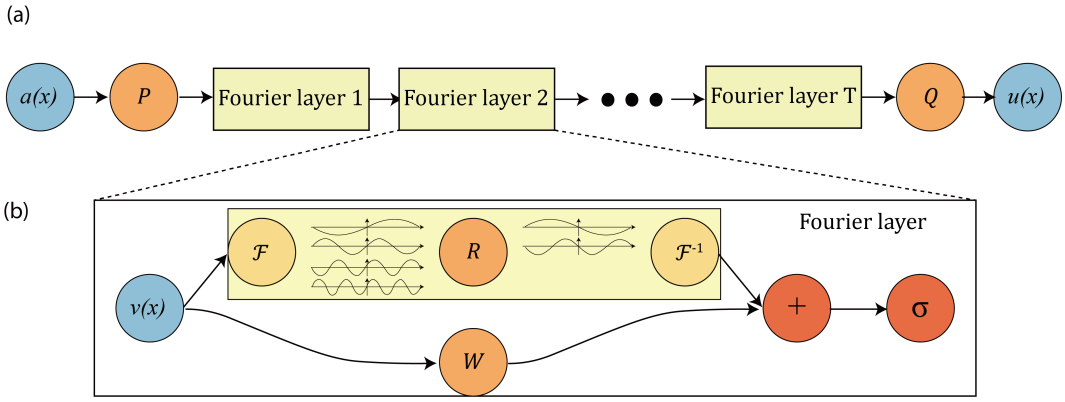

(a) 神经算子的完整架构：从输入a开始。1. 通过神经网络P将其提升至更高维的通道空间。2. 应用四层积分算子与激活函数。3. 通过神经网络Q将其投影回目标维度。输出u。**(b) 傅里叶层**：从输入v开始。上层：应用傅里叶变换F；对低阶傅里叶模态施加线性变换R以滤除高阶模态；随后应用逆傅里叶变换F^{-1}。下层：应用局部线性变换W。

图 2：**上图**：神经算子的架构；**下图**：傅里叶层。

(PINNs)（Raissi 等，2019）旨在解决后者问题，因此计算成本较高。这使得它们在需要针对多种不同参数实例求解偏微分方程（PDE）的应用场景中并不实用。另一方面，我们的方法直接对算子进行近似，因此计算成本更低、运算速度更快；与传统求解器相比，可实现显著的计算资源节省。有关贝叶斯逆问题的应用示例，请参阅第5.5节。

□**离散化。**由于我们的数据a_j和u_j通常为函数，为对其进行数值处理，我们假设仅能进行点值评估。令$D_j = \{x_1, \dots, x_n\$\in \mathcal{D}\$$为域$\mathcal{D}$的一个n点离散化网格，并假设我们拥有观测值$a_j|_{D_j}\$\mathcal{O}\$^{d_a}$与$u_j|_{D_j}\$\mathcal{O}\$$，这些观测值对应于由j索引的有限输入-输出对集合。为确保神经算子具有离散化不变性，该算子可对任意$\$x \in \mathcal{D}\$$（可能包含x）生成答案$u(x)$。$\notin D_j$.这一特性非常实用，因为它支持在不同网格几何结构与离散化方案之间进行求解结果的迁移。

3 神经算子

该神经算子由 (Li 等，2020b）提出，其构建为一种迭代架构$v_0 \to_i v_1 \to_i \dots \to_i v_T$，其中对于$j$= 0,1 ，... ，$T$—1，$v_j$是一个函数序列，每个函数的取值域为 R ^{d}。如图2(a) 所示，输入$a \in A$首先通过局部变换P（该变换通常由一个浅层全连接神经网络参数化）升维为高维表示$v_0(x) = P(a(x))$。随后，我们对$v_t \to_i v_{t+}$ （定义见下文）进行若干次迭代更新。输出$u(x) = Q(v_T(x))$ 是v_T经由局部变换Q: R $^{d_v} \to$ R ^{d_u}所得到的投影。在每次迭代中，更新量$v_t \to i v_{t+1}$定义为非局部积分算子K与局部非线性激活函数σ的复合运算。

定义 1（迭代更新）_将表示$v_t \to v_{t+1}$的更新定义为：_

$$v_{t+1}(x) := \sigma\big(W v_t(x) + (K(a; \Psi)v_t)(x)\big), \quad x \in D \tag{2}$$

_其中$\$K : A \times \Theta_K \to L(U(D; \mathbb{R}^{d_v}), U(D; \mathbb{R}^{d_v}))\$$ 映射到$\$U(D; \mathbb{R}^{d_v})\$$ 上的有界线性算子，并由$\$\phi \in \Theta_K\$$ 参数化；$\$W : \mathbb{R}^{\$\mathbf{dv}\$} \to \mathbb{R}^{\$\mathbf{dv}\$}\$$ 是一个线性变换，而$\$\sigma : \mathbb{R} \to \mathbb{R}\$$ 是一个非线性激活函数，其作用按分量方式定义。_

我们选择$K(a; \Psi)$ 作为由神经网络参数化的核积分变换算子。**定义 2（核积分算子K）**_定义（2) 式中的核积分算子映射为_

$$(\mathcal{K}(a; \Psi)v_t)(x) := \int_D \kappa(x, y, a(x), a(y); \Psi)v_t(y)dy, \quad x \in D \tag{3}$$

其中 $h_{\phi}:\mathbb{R}^{2(d+da)}\to\mathbb{R}^{\text{dv}\times\text{dv}}$ 是一个由 $\phi\in\Theta_{\kappa}$ 参数化的神经网络。

此处，h_{ϕ}作为一个从数据中学习得到的核函数。定义 1 与定义 2 共同构成了神经网络向无限维空间的推广——这一概念最早由Li 等（2020b）提出。值得注意的是，即使积分算子是线性的，神经算子仍可通过将线性积分算子与非线性激活函数相结合来学习高度非线性的算子，这与标准神经网络的运作机制类似。

若我们消除对函数a的依赖性，并假定$h_{\phi}(x, y)=h_{\phi}(x-y)$，则可得出 (3) 是一个卷积算子——从基本解的角度来看，这是一个自然的选择。在接下来的章节中，我们利用这一特性，将h_{ϕ}直接参数化于傅里叶空间，并采用快速傅里叶变换（FFT）高效计算式（3）。由此构建的快速计算架构在求解偏微分方程问题时取得了业界领先的性能。

4 傅里叶神经算子

我们建议用一个在傅里叶域中定义的卷积算子来替代式（3）中的核积分算子。

空间。令F表示函数$f: D \to \mathbb{R}^{d_v}$的傅里叶变换，且$F^{-1}$为其逆变换，则有$(\mathcal{F}f)_j(k)=\int_D$ $\int_{-\infty}^{\infty}\frac{1}{2\pi}\int_{-\infty}^{\infty} e^{i k x}\,dx$-$2i\pi\langle x, k\rangle dx$，$(F^{-1}f)_j(x)=\int_D f_j(k)e^{2i\pi\langle x, k\rangle}\,\mathrm{d}k$

对于$j=1$，...，d_v，其中$i=\sqrt{-1}$为虚数单位。通过令$h_{\phi}(x, y, a(x), a(y))=h_{\phi}(x-y)$ 代入式（3），并应用卷积定理，我们可得：

$$(K(a;\ \Psi)v_t)(x)=F^{-1}(F(h_{\Psi}).\ F(v_t))(x),\quad x\in D.$$ 因

此，我们建议直接在傅里叶空间中对h_{ϕ}进行参数化。**定义 3（傅里叶积分算子*K*)***定义傅里叶积分算子*

$$\big(\mathcal{K}(\phi)v_t\big)(x)=\mathcal{F}^{-1}\Big(R_{\phi}\cdot(\mathcal{F}v_t)\Big)(x)\qquad\forall x\in D \tag{4}$$

其中 R_{ϕ} 是周期函数 $h: D\to\mathbb{R}^{\mathbb{R}^d\times\mathbb{R}^d}$ 的傅里叶变换，该函数由 $\phi\in\Theta_{\kappa}$ 参数化。示意图见图2(b)。

对于频率模式$k\in D$，我们有$(\mathcal{F}v_t)(k)\in\mathbb{C}^{d_v}$且$R_{\phi}(k)\in\mathbb{C}^{d_v\times d_v}$。注意到由于我们假设$h$是周期函数，因此它可展开为傅里叶级数，因此我们可以对离散模式$k\in\mathbb{Z}^d$进行分析。我们通过在最大模式数$k_{\max}=|Z_{k_{\max}}|=|\{k\in\mathbb{Z}^d: |k_j|\le k_{\max}, j,$ 其中$j=1$，...，$d\}|$处截断傅里叶级数，从而实现有限维参数化。因此，我们将R_{ϕ}直接参数化为一个复值的 $(k_{\max}\times d_v\times dv)$-张量，该张量由一组截断的傅里叶模式构成，因此在符号表示中省略 Ψ。由于h是实值函数，我们施加共轭对称性。我们注意到，集合$Z_{k_{\max}}$并非用于定义v_t的低频模态的典型选择。实际上，低频模态通常是通过为$k\in\mathbb{Z}^d$的ℓ_1范数设定上界来定义的。我们选择上述$Z_{k_{\max}}$是因为其便于高效实现。

离散情形与 FFT 。假设定义域D通过$n\in\mathbb{N}$个点进行离散化，则有$v_t\in\mathbb{R}^{n\times d_v}$且$F(vt)\in\mathbb{C}^{n\times d_v}$。由于我们将$v_t$与一个仅具有$k_{\max}$个傅里叶模态的函数进行卷积，因此可直接截断高阶模态以得到$F(vt)\in\mathbb{C}^{k_{\max}\times d_v}$。随后对权重张量$R\in\mathbb{C}^{k_{\max}\times d_v\times d_v}$进行乘法运算。

$$\big(R\cdot(\mathcal{F}v_t)\big)_{k,l}=\sum_{j=1}^{d_v}R_{k,l,j}(\mathcal{F}v_t)_{k,j},\qquad k=1,\dots,k_{\max},\quad j=1,\dots,d_v. \tag{5}$$

当离散化为均匀离散且分辨率$s_1\times\cdots\times s_d=n$时，$F$可用快速傅里叶变换替代。对于$f\in\mathbb{R}^{n\times d_v}$，$k=(k_1, \dots, k_d)\in\mathbb{Z}_{s_1}\times\cdots\times\mathbb{Z}_{s_d}$，且$x=(x_1, \dots, x_d)\in D$，则 FFT $\mathcal{F}$及其逆变换 $\mathcal{F}^{-1}$定义为：

$$(\hat{\mathcal{F}}^{-1} f)_l(x) = \sum_{k_1=0}^{s_1-1} \cdots \sum_{k_d=0}^{s_d-1} f_l(k_1, \ldots, k_d) e^{2i\pi \sum_{j=1}^{d} \frac{x_j k_j}{s_j}}$$

对于l= 1，...，d_v。在这种情况下，截断模态集变为

$Z_{k_{\max}} = \{(k_1, \ldots, kd)\}$ $\mathbb{Z}_{s_1} \times \cdots \times \mathbb{Z}_{s_d}$ j k_j $k_{\max}$，$_j$或$s_j - k_j$ $k_{\max}$，$_j$，其中j= 1，...，d}。在实际实现时，R被视为一个 ($s_1 \times \cdots \times s_d \times d_v \times dv$)-张量，而上述$Z_{k_{\max}}$的定义对应于$R$的顶点，这使得通过矩阵-向量乘法对式 (5) 进行直接并行实现成为可能。在实际应用中，我们发现选择$k_{\max}$以及$_j$= 12（由此得出每个通道对应$k_{\max}$= 12 ^{d}个参数）对于我们所考虑的所有任务均足够。

参数化方法：R**。**一般而言，R可定义为依赖于 (Fa) 以符合 (3)。事实上，我们可以将R_{ϕ}: Z ^{d} × R ^{d_v} → R $^{do \times do}$定义为一个参数化函数，该函数将 $'k$，(Fa)(k)) 映射到相应傅里叶模态的数值上。我们尝试了R_{ϕ}的线性参数化方法与神经网络参数化方法。我们发现，线性参数化方法的性能与前述直接参数化方法相当，而神经网络的性能则较差。这很可能源于空间 Z ^{d} 的离散结构。本研究中的实验重点集中于上述直接参数化方法。

对离散化不变性。傅里叶层具有离散化不变性，因为它们能够从以任意方式离散化的函数中进行学习和评估。由于参数是在傅里叶空间中直接学习的，因此在物理空间中解析这些函数 simply 等同于对基向量$e^{2\pi i \langle x, k \rangle}$进行投影——这些基向量在 R ^{d}上的每个点处均明确定义。这使得我们能够实现零样本超分辨率重建，如第5.4节所示。此外，我们的架构在输入和输出的任意分辨率下均具有恒定的误差。另一方面，请注意，在图3中，我们所对比的标准 CNN 方法所对应的误差会随着分辨率的增加而增大。

准线性复杂度。权重张量R包含$k_{\max}$<n个模态，因此内积运算的复杂度为O($kmax$)。因此，大部分计算成本在于计算傅里叶变换F(vt) 及其逆变换。一般傅里叶变换的计算复杂度为O(n^2)；然而，由于我们对级数进行了截断，因此其实际计算复杂度为O(n^{k_max})，而 FFT 的计算复杂度为O(n log n)。总体而言，我们发现使用 FFT 具有很高的效率，但需采用均匀离散化处理。

5 数值实验

在本节中，我们将所提出的傅里叶神经算子与多种有限维架构以及基于算子的近似方法在一维Burgers方程、二维Darcy流问题及二维Navier-Stokes方程上进行对比。数据生成过程分别在附录A.3.1、A.3.2和A.3.3中讨论。我们未将本方法与传统求解器（FEM/ FDM）或神经-FEM类方法进行对比，因为我们的目标是构建一种可用于下游应用的高效算子近似方法。我们在第5.5节中展示了一个此类应用实例——贝叶斯逆问题。

我们通过堆叠四个傅里叶积分算子层来构建傅里叶神经算子，具体如公式（2）和公式（4）所述，其中采用 ReLU 激活函数及批量归一化层。除非另有说明，我们使用N= 1000 个训练样本和 200 个测试样本。采用 Adam 优化器进行 500 个训练轮次的训练，初始学习率为 0.001，每 100 个训练轮次将学习率减半。对于一维问题，设置$k_{\max}$、$_j$= 16，d_v= 64；对于二维问题，设置$k_{\max}$、$_j$= 12，d_v= 32。低分辨率数据由高分辨率数据下采样获得。所有计算均在一块配备 16GB 内存的 Nvidia V100 GPU 上完成。

关于分辨率的评述。传统的偏微分方程求解器（如有限元法 FEM 和有限体积法 FDM）是对单个函数进行近似，因此随着分辨率的提高，其对连续域的误差亦随之减小；而算子近似则与数据的离散化方式无关——只要所有相关信息均得到解析即可。如图3所示，分辨率不变算子在不同分辨率下具有一致的误差率。此外，分辨率不变算子支持零样本超分辨率处理，如第5.4节所述。

时不变问题的基准测试（Burgers 与 Darcy 方程）：NN：一个简单的逐点前馈神经网络。**RBM：**经典的降阶基法（采用 POD 基）（De-

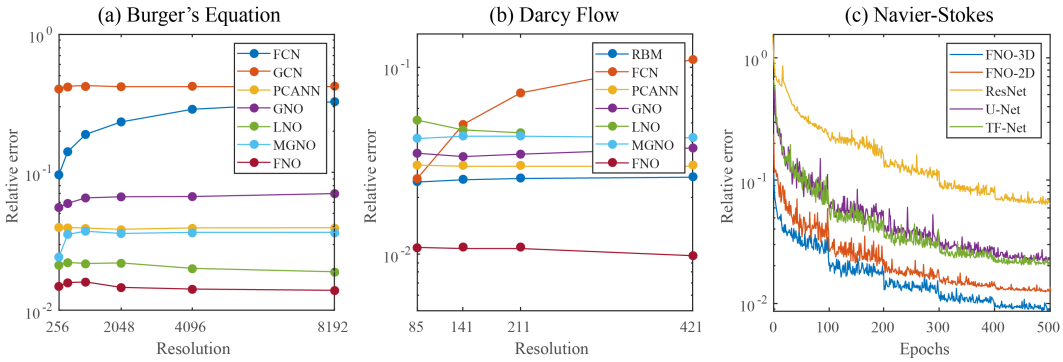

左图：Burgers 方程上的基准测试；**中图：**不同分辨率下 Darcy 流场上的基准测试；**右图：**Navier-Stokes 方程（ν= 1e-3）在不同基准测试下的学习曲线。训练与测试均在相同分辨率下进行。

关于缩写词，请参阅第5节；详细信息见表1、3及4。

图 3：Burger 方程、达西流及 Navier-Stokes 方程的基准测试

Vore，2014）。**FCN：**一种基于全卷积网络（Zhu & Zabaras，2018）的最先进神经网络架构。**PCANN：**一种运算方法，将 PCA 作为自编码器应用于输入和输出数据，并利用神经网络对潜在空间进行插值（Bhat Tacharya 等，2020）。**GNO：**原始图神经算子（Li 等，2020b）。**MGNO：**多极图神经算子（Li 等，2020a）。**LNO：**一种基于核函数$h(x, y) := \omega_{rj=1}\ \Psi_j(x)\Theta_j(y)$ 的低秩分解的神经算子方法，该方法与 (Lu 等，2019) 中提出的非堆叠 DeepONet 类似。**FNO：**新提出的一种傅里叶神经算子。

时变问题（Navier-Stokes方程）的基准模型：ResNet：由18层带残差连接的二维卷积层组成（He 等，2016）。**U-Net：**一种广泛用于图像到图像回归任务的模型，由四个包含二维卷积与反卷积层的模块构成（Ronneberger等，2015）。**TF-Net：**一种基于空间与时间卷积相结合的湍流流场学习网络（Wang 等，2020）。**FNO -2d：**具有时间方向上 RNN 结构的二维傅里叶神经算子。**FNO -3d：**一种直接在时空域上进行卷积运算的三维傅里叶神经算子。

5.1 伯格斯方程

一维Burgers方程是一个非线性偏微分方程，其应用范围广泛，包括对粘性流体的一维流动进行建模。该方程的形式为：

$$\partial_t u(x,t) + \partial_x(u^2(x,t)/2) = \nu\partial_{xx}u(x,t), \qquad x \in (0,1), t \in (0,1]$$
$$u(x,0) = u_0(x), \qquad x \in (0,1) \tag{6}$$

在周期性边界条件下，其中u_0。 $L^2_{\text{per}}((0,1);\ \text{R})$ 为初始条件，而$\mathcal{H}$。 R_+为粘性系数。我们旨在学习一个将初始条件映射至时刻为1时解的算子$G^\dagger: L^2_{\text{per}}((0,1);\ \text{R}) \to H^r_{\text{per}}((0,1);\ \text{R})$，该算子由$u_0 \to u(\cdot, 1)$ 对任意$r > 0$ 定义。实验结果如图3(a) 及表3（附录A.3.1）所示。与所有基准方法相比，我们提出的方法获得了最低的相对误差。此外，该误差与分辨率无关；而基于卷积神经网络的方法（FCN）的误差则随分辨率的增加而增大。与采用 Nystr 方法的其他神经算子方法（如 GNO 和 MGNO）相比.....ö在物理空间中进行 m 次采样时，傅里叶神经算子不仅精度更高，而且计算效率更优。

5.2 达西流体流动

我们研究单位立方体上二维达西流方程的稳态解；该方程是一个二阶线性椭圆型偏微分方程。

$$-\nabla \cdot (a(x)\nabla u(x)) = f(x)，\text{其中 x。}\ (0，1)^2$$
$$u(x) = 0 \qquad x \in \partial(0,1)^2 \tag{7}$$

该方程具有 Dirichlet 边界条件，其中a。 $L^{\infty}((0,1)^2$； R+) 为扩散系数，而f。 $L^{2}((0,1)^2$； R) 为外力函数。该偏微分方程具有广泛的应用，包括模拟地下流体压力、线性弹性材料的变形以及导电材料中的电势分布。我们旨在学习将扩散系数映射到解上的算子$G^{\dagger}$:$L^{\infty}((0,1)^2$； R+)→ $H10((0,1)^2$； R+)，其定义为a →} u。需要注意的是，尽管该偏微分方程是线性的，但算子$G^{\dagger}$并非线性。

我们的实验结果如图3(b) 和表4（附录A.3.2）所示。与所有基准方法相比，所提出的傅里叶神经算子所获得的相对误差降低了近一个数量级。我们再次观察到该误差值对分辨率具有不变性。

5.3 纳维-斯托克斯方程

我们考虑单位环面上粘性、不可压缩流体的二维Navier-Stokes方程（以涡量形式表述）：

$$\begin{aligned} \partial_t w(x,t) + u(x,t)\cdot\nabla w(x,t) &= \nu\Delta w(x,t) + f(x), && x\in(0,1)^2, t\in(0,T] \\ \nabla\cdot u(x,t) &= 0, && x\in(0,1)^2, t\in[0,T] \\ w(x,0) &= w_0(x), && x\in(0,1)^2 \end{aligned} \tag{8}$$

其中u。 $C([0，T]$； $H^r_{\text{per}}((0,1)^2$； R ^{2})) 对任意r >0 表示速度场，w=▿ × u表示涡度，w_0。 $L^2_{\text{per}}((0,1)^2$； R) 表示初始涡度，ν。 R_+表示黏性系数，而f。 $L^2_{\text{per}}((0,1)^2$； R) 表示外力函数。我们旨在研究将时间 10 时刻的涡量映射至某个后续时刻 $$T$ >10 时刻的算子$G^{\dagger}$：C ([0, 10];$H^r_{\text{per}}((0, 1)^2$;\mathbb{R}→$C((10,T]$;$H^r_{\text{per}}((0, 1)^2$;\mathbb{R}))，其定义为$w_j_{(0,1)^2\times[0,10]}$ →$w\_j_{(0;\ 1)^2\times(10;\ T]}$。给定涡量后，推导速度十分简便；而相较于速度，涡量的建模难度更大，但能提供更多信息。通过将问题表述为基于涡量的形式，神经网络模型模拟了伪谱法。我们采用黏度参数ν=10^{-3}$、$10^{-4}$、$10^{-5} 进行实验，并随着系统趋于混沌而减小最终时间T。由于基准方法不具备分辨率不变性，我们在训练和测试阶段均将分辨率固定为 64*times* 64$。

表1：Navier-Stokes方程基准测试（固定分辨率：64）× 64（训练集与测试集均适用）

配置	参数	时间 由 轮	$\nu=1\text{e}{-3}$ $T=50$ $N=1000$	$\nu=1\text{e}{-4}$ $T=30$ $N=1000$	$\nu=1\text{e}{-4}$ $T=30$ $N=10000$	$\nu=1\text{e}{-5}$ $T=20$ $N=1000$
FNO-3D	$6,558,537$	$38.99s$	**0.0086**	0.1918	**0.0820**	0.1893
FNO-2D	$414,517$	$127.80s$	0.0128	**0.1559**	0.0834	**0.1556**
U-Net	$24,950,491$	$48.67s$	0.0245	0.2051	0.1190	0.1982
TF-Net	$7,451,724$	$47.21s$	0.0225	0.2253	0.1168	0.2268
ResNet	$266,641$	$78.47s$	0.0701	0.2871	0.2311	0.2753

如表1所示，当数据量充足时（ν= 1e—3，N= 1000 以及ν= 1e—4，N= 10000）， FNO -3D 的性能最佳。而在数据量不足的配置下（ν= 1e—4，N= 1000 以及ν= 1e—5，N= 1000），所有方法的误差均大于 15%，其中 FNO -2D 的误差最小。请注意，我们仅展示空间分辨率为 64 × 64 的结果，因为我们所对比的所有基准测试均针对该分辨率设计；提高分辨率会降低其性能，而 FNO 则能保持相同的误差水平。

二维与三维卷积运算。FNO -2D、U-Net、TF-Net 和 ResNet 均在空间域执行二维卷积运算，并在时间域中进行循环传播（2D+ RNN）。该运算符将前 10 个时间步长上的解映射至下一个时间步长（二维函数映射为二维函数）。另一方面， FNO -3D 在时空域上执行卷积运算，它将初始时间步长直接映射至整个轨迹（三维函数映射为三维函数）。2D+ RNN 结构可将解按固定间隔长度 ▵ t的增量传播至任意时间T；而 Conv3D 结构则固定于区间 [0，T]，但可将解传递至任意时间离散化格式。我们发现，与采用 RNN 结构的对应方法相比，该三维方法具有更强的表达能力且更易于训练。

5.4 零点超分辨率。

该神经算子具有网格不变性，因此可在较低分辨率下进行训练并在较高分辨率下进行评估，而无需接触任何高分辨率数据（零样本超分辨率）。图1展示了一个示例：我们在上述设置下，使用 64 × 64 × × 20 分辨率的数据（参数设置为ν= 1e-4，N= 10000）对 FNO -3D 模型进行训练，随后将其迁移至 256 × 256 × × 80 分辨率，从而实现时空域超分辨率重建。在基准模型（FNO -2D、U-Net、TF-Net 和 ResNet）中，傅里叶神经算子是唯一能够实现零样本超分辨率重建的模型。令人惊讶的是，该模型不仅能实现空间域超分辨率重建，还能实现时域超分辨率重建。

5.5 贝叶斯逆问题

在本实验中，我们采用函数空间马尔可夫链蒙特卡罗（MCMC）方法（Cotter等，2013）从Navier-Stokes方程中初始涡度的后验分布中抽取样本，该方程基于时间T= 50 时获取的稀疏且含噪的观测数据。我们将作为代理模型使用的傅里叶神经算子与用于生成训练集和测试集的传统求解器（两者均在 GPU 上运行）进行对比。我们从后验分布中生成了 25,000 个样本（其中包含 5,000 个样本的预烧期），这需要对前向算子进行 30,000 次求值。

如图6（附录A.5）所示， FNO 与传统求解器计算出的后验均值几乎相同；将该结果反向应用时，能够很好地还原 Navier-Stokes 方程的后期动力学行为。相比之下，使用 FNO 计算单个实例仅需 0.005 秒，而传统求解器在经过优化（采用不会导致数值发散的最大可能内部时间步长）后，计算时间则为 2.2 秒。这意味着，使用 FNO 的 MCMC 执行计算耗时 2.5 分钟，而传统求解器则需超过 18 小时。即使将数据生成与训练时间（离线步骤）计入内（共需 12 小时），使用 FNO 仍更为高效！一旦完成训练， FNO 可用于快速执行多个针对不同初始条件和观测数据的 MCMC 模拟运算，而传统求解器对每个实例的计算时间则需 18 小时。此外，由于 FNO 是可微的，因此可直接应用于具有偏微分方程约束的优化问题，而无需使用伴随法。

光谱分析。由于我们对R_ϕ进行参数化的方式，由式（4）输出的函数在每个通道上最多具有$k_{\max}$，J个傅里叶模态。然而，这并不意味着傅里叶神经算子只能对不超过$k_{\max}$，J个模态的函数进行近似。实际上，出现在积分算子与最终解码器网络Q之间的激活函数能够恢复高频模态。例如，考虑一个黏度为ν= 1e-3 的纳维-斯托克斯方程的解。对该函数进行截断至 20 个傅里叶模态时，误差约为 2%；而我们的傅里叶神经算子能够学习其参数依赖性，并在仅使用$k_{\max}$，J= 12 个参数化模态的情况下，产生误差 1% 的近似解。

非周期边界条件。传统傅里叶方法仅适用于周期性边界条件。然而，傅里叶神经算子并不受此限制。这得益于线性变换W（偏置项）对非周期边界条件的追踪作用。例如，达西流场及纳维-斯托克斯方程在时域中均存在非周期边界条件，而傅里叶神经算子仍能以极高的精度学习出相应的解算子。

6 讨论与结论

数据需求。数据驱动方法依赖于数据的质量与数量。为学习黏度ν= 1e-4 的纳维-斯托克斯方程，我们需要利用数值求解器生成N= 10000 个训练样本对 $\{a_j, u_j\}$。然而，对于更具挑战性的偏微分方程，仅生成少量训练样本可能已成本高昂。未来的一个研究方向是将神经算子与数值求解器相结合，从而降低对数据的需求。**循环结构。**神经算子具有迭代结构，该结构可自然地表述为一个循环神经网络——其中所有层共享相同的参数且不牺牲性能。（我们在实验中并未强制执行这一限制。）**)计算机视觉。**操作符学习并不局限于偏微分方程（PDEs）。图像可自然地视为定义在二维域上的实值函数，而视频则简单地增加了时间维度。因此，我们的方法是解决计算机视觉中对离散化不变性至关重要的问题的天然选择（Chi 等，2020）。

致谢

作者谨感谢 Ray Wang 和 Rose Yu 提供的富有意义的讨论。Z. Li 感谢 Kortschak 学者计划提供的资金支持。A. Anandkumar 部分受 Bren 慰捐赠讲席、LwLL 拨款、Beyond Limits 项目、Raytheon、Microsoft、Google、Adobe 教职研究员基金以及 DE Logi 拨款的支持。K. Bhattacharya、N. B. Kovachki、B. Liu 和 A。
M. Stuart 感谢美国陆军研究实验室通过合作协定（编号：W911NF-12-0022）提供的资金支持。本研究由美国陆军研究实验室资助，并依据合作协定（编号：W911NF-12-2-0022）开展。本文所载观点与结论仅代表作者个人意见，不应被解释为美国陆军研究实验室或美国政府（无论明示或暗示）的官方政策。尽管本文中可能包含有关版权的声明，但美国政府有权为政府用途复制并分发本文件的副本。

参考文献

Jonas Adler 与 Ozan Oktem：利用迭代深度神经网络求解不适定逆问题。*《逆问题》*，2017 年 11 月 。doi: 10.1088/1361-6420/aa9581。URL https://doi.org/10.1088/1361-6420/aa9581。

Leah Bar 与 Nir Sochen：基于偏微分方程的正向与逆向问题的无监督深度学习算法。*arXiv 预印本 arXiv:1904.05417*，2019年。

Yoshua Bengio, Yann LeCun,等.面向人工智能的规模化学习算法.*大规模核机器学习*,《34(5): 1–41》,2007年.

Saakaar Bhatnagar、Yaser Afshar、Shaowu Pan、Karthik Duraisamy 与 Shailendra Kaushik。基于卷积神经网络的气动流场预测。《*计算力学*》，第 1–21 页，2019 年。

Kaushik Bhattacharya、Nikola B. Kovachki 与 Andrew M. Stuart。《参数偏微分方程（PDE）的模型降维与神经网络》。*预印本*，2020年。

卢奇、江博瑞与穆亚东。《快速傅里叶卷积》。*《神经信息处理系统进展》*，第33卷，2020年。

S. L. Cotter、G. O. Roberts、A. M. Stuart 与 D. White。《适用于函数的 MCMC 方法：优化旧算法以提升计算速度》。*《统计科学》*，第 28 卷（第 3 期）：424–446 页，2013 年 8 月。ISSN 0883-4237。
doi: 10.1214/13-sts421. URL http://dx.doi.org/10.1214/13-STS421.

Ronald A. DeVore。*第 3 章：降基法的理论基础*。2014 年 。doi：10.1137/1。*9781611974829.ch3. URL* https://epubs.siam.org/doi/abs/10.1137/1.9781611974829.ch3。

魏南 E 与 王宇。深度Ritz法：一种基于深度学习的求解变分问题的数值算法。*《数学与统计通讯》*，第3卷，2018年。ISSN 2194-6701。doi: 10.1007/s40304-018-0127-z。

范宇威、Cindy Orozco Bohorquez 与 Ying Lexing。Bcr-net：一种基于非标准小波形式的神经网络。*《计算物理学杂志》*，384：1–15,2019a。

范宇威、林林、应乐星与莱昂纳多·塞佩达-努涅斯。基于层次矩阵的多尺度神经网络。*《多尺度建模与仿真》*，17(4):1189–1213,2019b。

Daniel Greenfeld、Meirav Galun、Ronen Basri、Irad Yavneh 与 Ron Kimmel。《学习优化多网格偏微分方程求解器》。载于*《国际机器学习会议》*，第 2415–2423 页。 PMLR，2019。

郭晓晓、李伟与 Francesco Iorio。《卷积神经网络在稳态流近似中的应用》。载于*《第22届 ACM SIGKDD 国际知识发现与数据挖掘会议论文集》*，2016年。

何凯明、张向宇、任绍庆与孙健。《深度残差学习在图像识别中的应用》。载于*《IEEE计算机视觉与模式识别会议论文集》*，第770–778页，2016年。

Kurt Hornik, Maxwell Stinchcombe, Halbert White,等.多层前馈神经网络是通用逼近器.*《神经网络》*,第 2 卷第 5 期,第 359–366 页,1989 年.

Chiyu Max Jiang, Soheil Esmaeilzadeh, Kamyar Azizzadenesheli, Karthik Kashinath, Mustafa Mustafa, Hamdi A Tchelepi, Philip Marcus, Anima Anandkumar,等.MeshfreeFlownet:一种基于物理约束的深度连续时空超分辨率框架.*arXiv预印本 arXiv:2005.01463*,2020年.

Karthik Kashinath, Philip Marcus,等.通过可微分偏微分方程层在 CNN 中实施物理约束. In *ICLR 2020 "Deep Neural 模型与 Differential Equations 集成研讨会"*,2020年.

Yuehaw Khoo、Jianfeng Lu 与 Lexing Ying。利用人工神经网络求解参数化偏微分方程问题。*arXiv预印本 arXiv:1707.03351*，2017年。

Dmitrii Kochkov、Jamie A Smith、Ayya Alieva、Qing Wang、Michael P Brenner 与 Stephan Hoyer。《机器学习加速计算流体力学》。*arXiv预印本 arXiv:2102.01010*，2021年。

李宗毅、Nikola Kovachki、Kamyar Azizzadenesheli、Liu Burigede、Kaushik Bhattacharya、Andrew Stuart 与 Anima Anandkumar。《用于参数化偏微分方程的多极图神经算子》，2020a。

李宗毅、尼古拉·科瓦奇基、卡米亚尔·阿齐兹达内谢利、刘伯吉德、考希克·巴塔查里亚、安德鲁·斯图尔特及阿尼玛·安南库马尔。神经算子：用于偏微分方程的图核网络偏微分方程。*arXiv预印本 arXiv:2003.03485*，2020b。

Lu Lu、Pengzhan Jin 与 George Em Karniadakis。Deeponet：基于算子的通用逼近定理学习非线性算子以识别微分方程。*arXiv预印本 arXiv:1910.03193*，2019年。

Michael Mathieu、Mikael Henaff 与 Yann LeCun。《通过 FFT 实现卷积神经网络的快速训练》，2013年。

Luis Mingo、Levon Aslanyan、Juan Castellanos、Miguel Diaz 与 Vladimir Riazanov。《傅里叶神经网络：一种采用正弦激活函数的方法》，2004年。

NH Nelsen 与 AM Stuart。用于巴拿赫空间间输入-输出映射的随机特征模型。*arXiv预印本 arXiv:2005.10224*，2020年。

邵武潘与 Karthik Duraisamy。基于物理信息的概率性学习方法用于非线性动力学线性嵌入的建模——并保证系统稳定性。*《SIAM 应用动力系统杂志》*，19(1): 480–509,2020年。

Ravi G. Patel、Nathaniel A. Trask、Mitchell A. Wood 与 Eric C. Cyr：一种基于物理信息的算子回归框架用于提取数据驱动的连续介质模型。*《应用力学与工程中的计算机方法》*，第 373 卷，第 113500 页，2021 年。

Maziar Raissi、Paris Perdikaris 与 George E. Karniadakis。《基于物理信息的神经网络：一种用于求解涉及非线性偏微分方程的正向与逆向问题的深度学习框架》。*《计算物理学杂志》*，378：686–707,2019年。

奥拉夫·罗内贝格尔、菲利普·菲舍尔与托马斯·布罗克斯。《U-Net：用于生物医学图像分割的卷积神经网络》。载于 *"国际医学图像计算与计算机辅助介入治疗会议"*，第 234–241 页。Springer，2015年。

Vincent Sitzmann、Julien NP Martel、Alexander W Bergman、David B Lindell 与 Gordon Wetzstein。基于周期性激活函数的隐式神经表征。*arXiv预印本 arXiv:2006.09661*，2020年。

Jonathan D. Smith、Kamyar Azizzadenesheli 与 Zachary E. Ross。《Eikonet：利用深度神经网络求解eikonal方程》。*arXiv预印本 arXiv:2004.00361*，2020年。

Vladimir N.Vapnik.*《统计学习理论》*. Wiley-Interscience,1998.

王瑞、Karthik Kashinath、Mustafa Mustafa、Adrian Albert 与 Rose Yu。《面向湍流流场预测的物理信息深度学习方法》。载于*《第 26 届 ACM SIGKDD 国际知识发现与数据挖掘会议论文集》*，第 1457–1466 页，2020 年。

Yinhao Zhu 和 Nicholas Zabaras 。基于贝叶斯深度卷积编码器–解码器网络的替代建模与不确定性量化方法。*《Journal of Computational Physics 》*，2018 年。ISSN 0021-9991。doi：https://doi.org/10.1016/j.jcp.2018.04.018。http://www.sciencedirect.com/science/article/pii/S0021999118302341。

A 附录

A.1 符号表

符号表见表2。

表2：符号表

符号表示法	含义
操作员学习	
$D \subset \mathbb{R}^d$ $x \in D$	偏微分方程的空间域 空间域中的点
$a \in \mathcal{A} = (D; \mathbb{R}^{d_a})$ $u \in \mathcal{U} = (D; \mathbb{R}^{d_u})$ D_j	输入系数函数 目标求解函数 (a_j, uj) 的离散化
$G^\dagger : \mathcal{A} \to \mathcal{U}$ μ	将系数映射至解的算子；一个概率测度，其中a_j从该测度中采样。
神经算子	
$v(x) \in \mathbb{R}^{d_v}$	$u(x)$ 的神经网络表示
d_a d_u d_v	输入参数$a(x)$ 的维度。 输出$u(x)$ 的维度。
$\kappa : \mathbb{R}^{2(d+1)} \to \mathbb{R}^{d_v \times d_v}$	表示$v(x)$ 的维度；核映射 (x，y，$a(x)$，$a(y)$) 转换为$d_v \times d_v$矩阵；核网络的参数h
ϕ	时间步长（层数）
$t = 0, \ldots, T$ σ	激活函数
傅里叶算子	
$\mathcal{F}, \mathcal{F}^{-1}$	傅里叶变换及其逆变换。
R	对低阶傅里叶模态施加的线性变换；对空间域施加的线性变换（偏置项）；傅里叶模态/波数。
W	
k	傅里叶层中使用的最大傅里叶模态。
k_{max}	
超参数	
N	训练数据对的数量。
n	离散化步长。
s	离散化分辨率（s^d=n）。
ν	粘度。
T	时变方程的时间区间为 [0，T]。

A.2 光谱分析

Navier-Stokes 方程数据的频谱衰减情况如图4所示。该频谱衰减的斜率为$k^{-5/3}$，与湍流区域的能量谱相符；此外，我们注意到能量谱并未随时间衰减。

我们还展示了以k_{max}（其定义见4）为参数的频谱衰减情况，如图5所示。我们注意到，所有方程（Burgers、Darcy 以及ν 1e-4 的 Navier-Stokes 方程）均呈现高频率模态。即使在傅里叶层中将截断值设为k_{max}= 12，傅里叶神经算子仍能恢复这些高频率模态。

A.3 数据生成

本节详细介绍了我们在第5节中所用的三元方程组的数据生成器。

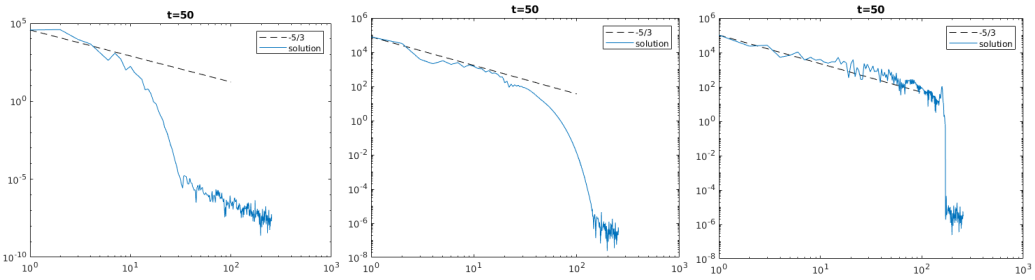

我们在研究中所采用的纳维-斯托克斯方程数据的频谱衰减特性5.3。y轴为频谱；+k。x轴表示波数$jk\,j=k_1\,{}_2$

图 4：Navier-Stokes 方程的频谱衰减特性

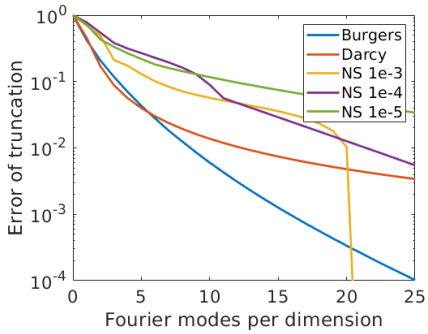

在未施加线性变换R的情况下，单个傅里叶层中的截断误差。y轴表示归一化截断误差；x轴表示截断模式k_{max}。

图 5：以k_{max}表示的频谱衰减曲线

A.3.1 burgers 方程

回顾单位环面上的一维Burger方程：$\nabla_t u(x, t) + \nabla_x(u \quad x \in (0,1), t \in (0,1]$

$^2(x, t)/2) = \mathcal{A}\nabla_{xx} u(x, t)$，

$$u(x,0) = u_0(x), \qquad x \in (0,1).$$

初始条件$u_0(x)$ 是根据$u_0 \sim \mathcal{A}$ 生成的，其中 $\mathcal{A} = N(0,625(-\Delta + 25I)^{-2})$ 且采用周期性边界条件。我们将黏性系数设为$\mathcal{A} = 0.1$，并采用分步法求解该方程：其中热方程部分在傅里叶空间中精确求解，随后非线性部分同样在傅里叶空间中采用非常精细的前向欧拉法进行推进。我们在分辨率为 $2^{13} = 8192$ 的空间网格上进行求解，并利用该数据集对其他分辨率进行子采样。

A.3.2 达西流体流动

二维达西流问题是一个形如以下的二阶线性椭圆型方程：

$$-\nabla \cdot (a(x)\nabla u(x)) = f(x)，其中 x。 (0, 1)^2$$

$$u(x) = 0 \qquad x \in \partial(0,1)^2.$$

系数$a(x)$ 是根据$a \sim \mathcal{A}$ 生成的，其中 $\mathcal{A} = \Theta_{\#}N(0, (-\Delta + 9I)^{-2})$，且在拉普拉斯算子上施加零诺伊曼边界条件。映射 Θ: R → R 在实数轴的正半轴上取值为 12，在负半轴上取值为 3，其推前运算按点定义。外力保持恒定$f(x) = 1$。此类构造是许多物理系统的典型模型，例如地下流场中的渗透率问题以及弹性力学中的材料微观结构问题。解u是通过在 421 × 421 网格上采用二阶有限差分格式求得的。从该数据集中提取了不同分辨率的样本。

A.3.3 NAVIER-斯托克斯方程

回顾单位环面上粘性、不可压缩流体的涡度形式二维Navier-Stokes方程：

$$\begin{aligned} \partial_t w(x,t) + u(x,t)\cdot\nabla w(x,t) &= \nu\Delta w(x,t) + f(x), && x\in(0,1)^2, t\in(0,T] \\ \nabla\cdot u(x,t) &= 0, && x\in(0,1)^2, t\in[0,T] \\ w(x,0) &= w_0(x), && x\in(0,1)^2. \end{aligned}$$

初始条件$w_0(x)$ 是根据$w_0\sim$ 生成的，其中 =$N(0,7^{3/2}(-\Delta+49I)^{-2.5})$ 且满足周期性边界条件。外力保持恒定$f(x) = 0.1(\sin(2\pi(x_1+x_2)) + \cos(2\pi(x_1+x_2)))$。该方程采用流函数表述法结合伪谱法求解。首先在傅里叶空间求解泊松方程以确定速度场。随后对涡度进行求导，并在物理空间中计算非线性项，之后对该项进行去aliasing处理。时间步进采用 Crank–Nicolson 更新法进行推进，且非线性项不参与隐式部分的计算。所有数据均在 256 × 256 的网格上生成，随后下采样至 64 × 64。在数据生成过程中，我们对 Crank–Nicolson 方程组采用时间步长 1×10^{-4}，并在每t= 1 个时间单位时记录一次解；而在应用至 MCMC 求解贝叶斯逆问题时，该时间步长增大为 2×10^{-2}。

A.4 Burgers方程与Darcy流场结果

Burgers方程与Darcy流问题的细节误差率列于表3与表4中。

表 3：一维 Burgers 方程基准测试结果

网络规模	s= 256	s= 512	s= 1024	s= 2048	s= 4096	s= 8192
NN	0.4714	0.4561	0.4803	0.4645	0.4779	0.4452
GCN	0.3999	0.4138	0.4176	0.4157	0.4191	0.4198
FCN	0.0958	0.1407	0.1877	0.2313	0.2855	0.3238
PCANN	0.0398	0.0395	0.0391	0.0383	0.0392	0.0393
GNO	0.0555	0.0594	0.0651	0.0663	0.0666	0.0699
LNO	0.0212	0.0221	0.0217	0.0219	0.0200	0.0189
MGNO	0.0243	0.0355	0.0374	0.0360	0.0364	0.0364
FNO	**0.0149**	**0.0158**	**0.0160**	**0.0146**	**0.0142**	**0.0139**

表4：二维达西流场基准测试

网络	s= 85	s= 141	s= 211	s= 421
NN	0.1716	0.1716	0.1716	0.1716
FCN	0.0253	0.0493	0.0727	0.1097
PCANN	0.0299	0.0298	0.0298	0.0299
RBM	0.0244	0.0251	0.0255	0.0259
GNO	0.0346	0.0332	0.0342	0.0369
LNO	0.0520	0.0461	0.0445	–
MGNO	0.0416	0.0428	0.0428	0.0420
FNO	**0.0108**	**0.0109**	**0.0109**	**0.0098**

A.5 贝叶斯逆问题

Navier-Stokes 方程的贝叶斯逆问题求解结果如图6所示。可以看出，采用傅里叶神经算子作为代理模型所得到的结果与传统求解器所得的结果相当。

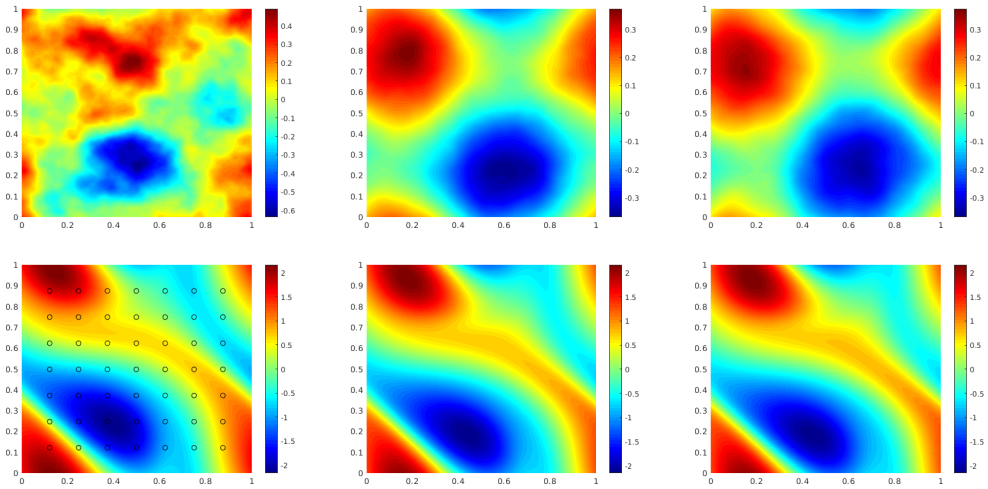

左上子图显示了真实的初始涡度，而左下子图显示了在T= 50 时的真实观测到的涡度；其中黑色圆点标示了布置在 7 × 7 网格上的观测点位置。上中子图展示了基于使用传统求解器通过 MCMC 方法估计的含噪声观测数据所得到的初始涡度的后验均值；而右上子图展示了使用 FNO 作为代理模型时的相同结果。下中子图与右子图分别展示了当采用相应的近似后验均值作为初始条件时，在T= 50 时的涡度分布。

图 6：Navier-Stokes 方程的贝叶斯逆问题求解结果。