目录列表可查阅于ScienceDirect

机械系统与信号处理

期刊主页：www.elsevier.com/locate/ymssp



全文文章

# 用于超声波全波形反演的神经网络算子：A 新一代超声波 NDT，具备更优的保真度、效率及鲁棒性

江璐[a]刘丽帅[a,*]袁丽[a]、王世君[b]、向艳春[a,*]

[a] 华东理工大学机械与动力工程学院智能传感与检测技术上海重点实验室，上海 200237，中国

[b] 中国国家电网甘肃省电力公司，邮编：730050

ARTICLE INFO

*关键词：*
傅里叶神经算子、全波形反演、超声定量检测、计算波场成像、深度学习

ABSTRACT

全波形反演（FWI）是一种将波动传播的物理机制全面纳入其中的计算波场成像技术，它能够实现非均匀介质的高分辨率定量重建，并促进其在无损检测（NDT）中的有效应用。然而，该方法的广泛应用受到解决非线性、不适定逆问题所固有的挑战的制约；考虑到其迭代实现方式、对初始模型的敏感性以及可能收敛于局部极小值解等因素，这导致了较高的计算成本。近年来，基于神经网络的数据驱动型 FWI 框架取得了显著进展，提升了计算精度与效率，但其鲁棒性与泛化能力方面仍存在挑战。神经算子作为科学机器学习领域的一种新兴范式，旨在学习无限维函数空间之间的映射关系，为复杂物理系统提供了更优的泛化能力和扩展性。受此启发，我们提出一种基于神经算子的框架，用于对超声全波形数据进行直接反演，该框架基于Unet傅里叶神经算子（U- FNO），将神经算子范式拓展至超声波全波形反演（Ultrasonic Full-Waveform Inversion，NDT）领域。通过采用参数化傅里叶核函数全局捕捉复杂的波场物理现象，U- FNO 相较于经典 FWI 方法具有更高的推理效率；与典型的数据驱动模型及全聚焦法（TFM）相比，其重建保真度与鲁棒性均有所提升。数值模拟与实验结果表明，该框架为下一代超声波 NDT 计算波场成像技术的发展提供了极具前景的研究方向。

## 1. 引言

声学成像技术旨在通过分析测得的波信号[1]来推断材料内部隐藏的结构及未知的物理性质。该技术在众多应用领域中发挥着至关重要的作用，例如地震反演、水下物体检测、生物医学成像以及无损检测（NDT）。这一任务通常涉及求解不适定且非线性的逆问题；特别地，传感器数据通常仅在物体表面或边界处获取，这导致有限的观测数据与未知参数空间之间存在维度不匹配问题。此外，介质固有的非均匀性会引发诸如衍射、散射和反射等复杂的波动现象。因此，单次观测数据可能

* 通讯作者。
*电子邮箱地址：*lishuai.liu@ecust.edu.cn（L. Liu）、yxxiang@ecust.edu.cn（Y. Xiang）。

https://doi.org/10.1016/j.ymssp.2026.114179
2025年9月26日收到；2026年3月4日收到修订稿；2026年3月18日接受
2026年4月7日线上发布
0888-3270/© 2026 Elsevier Ltd. 保留所有权利，包括文本与数据挖掘、人工智能训练及类似技术领域的权利。

对应于多个物理上合理的解，从而增加了反演过程的难度与不确定性。

为应对这些挑战，人们开发了多种成像方法，如图 1所示。早期的方法主要基于射线近似法，其计算效率高且稳定性好；代表性技术包括合成孔径聚焦法（SAFT）[2]、全聚焦法（TFM）[3]、概率诊断成像法（PDI）[4]以及平面波成像法（PWI）。然而，这些方法本质上仅适用于定性重建，因为所得图像仅近似反映了声学参数的空间变化。基于射线的层析成像法[5]仅根据走时来估算介质中的声速分布，可提供粗略的定量分析；该方法忽略了波的衍射与散射效应，因此其分辨率受限于第一菲涅耳区的宽度[6,7]。为在保持计算效率的同时改进基于射线的方法，波场外推法（如相位移偏移法（PSM）[8]与Stolt偏移法[9]）采用了单向波近似法来部分考虑衍射效应。衍射层析成像技术利用线性化散射场近似法（例如Born近似或Rytov近似），同时考虑了衍射与散射效应[10]，并能提高对简单缺陷的分辨率；然而，其适用范围仍局限于弱散射情况，对于具有高速度对比度的复杂缺陷则无法有效应用[11]。

全波形反演（FWI）已成为一种强大的定量地下结构重建方法，通过最小化观测数据与合成数据之间的不匹配度，实现高分辨率、高精度的地下结构重建[12,13]。该方法的高分辨率特性源于对精确波动方程的数值求解——该方程能更完整地描述非均匀介质中波传播的物理机制；利用该方法可实现相当于主频波长一半的分辨率[14,15]。然而，由于频率范围、波传播特性以及材料间较高的声阻抗差异等因素，将 FWI 直接应用于超声波无损检测（Ultrasonic NDT）面临诸多挑战。因此，尽管 FWI 在推动超声波无损检测技术发展方面具有广阔前景，但其实际应用迄今仍局限于少量初步研究中。例如，Rao 等人。[16] 他们开发了一种声学多参数 FWI 方法，用于重建金属构件的速度场与密度场；此外，他们还将该方法拓展应用于导波腐蚀损伤的定量成像[17]。另外，He 等人。[18] 研究了 FWI 技术在水浴环境下重建复杂金属部件中的应用。其数值评估结果表明， FWI 在准确恢复复杂结构特征方面具有显著潜力。为进一步验证这些发现，随后利用精确的传感器建模对均质材料进行了实验研究[19]。Burchner 等人。[20] 本研究从多个指标角度对 TFM 、RTM 和 FWI 方法在相控阵全矩阵采集（FMC）数据中的应用进行了定量比较，突显了 FWI 方法在缺陷识别与尺寸测定方面的强大潜力。然而， FWI 方法计算成本较高，因为每次迭代都需要在非线性优化框架下对整个波场进行正向建模；此外，其固有的非线性特征与不适定性常导致算法收敛至局部极小值，使得重建结果对初始模型的质量极为敏感[13]。为解决上述问题，目前已开发出多种基于物理原理的方法，包括：开发正则化方法[21]、利用低频信息构建改进的初始模型[22]、优化目标函数的凸性[23]以及采用多尺度优化策略[24]。尽管取得了这些进展，基于物理原理的 FWI 方法在超声波 NDT 逆问题中仍未取得一致性的成功应用，这凸显了寻求替代性解决方案的必要性。

受深度学习领域飞速发展的推动——该技术已展现出在不同数据域之间建立非线性映射的强大能力——研究人员提出了数据驱动的直接反演方法，以减轻传统 FWI[25,26]所带来的优化负担。这些方法的主要目标是将FWI的优化问题转化为一个监督学习任务；该任务通过在波形与介质声学参数的配对数据上训练神经网络，构建从观测数据到测量结构的逆映射关系，此类方法在文献中亦被称为数据驱动的 FWI[27–30]。基于不同神经网络架构的数据驱动直接反演方法在地震勘探领域取得了显著成效，尤其是在计算效率和反演精度方面[25–31]。近期，此类方法亦被应用于超声成像领域。Suo 等。[32] 研究人员开发出一种改进的基于双编码器的 UNet 模型，该模型采用高频特征增强技术，用于骨声速与骨密度的定量成像；该方法有效解决了由高对比度骨模型所引发的 FWI 中存在的高度非线性问题。Lozenski 等。[33] 进一步凸显了利用卷积神经网络（CNN）进行 FWI 学习所具有的计算优势——其重建速度比传统 FWI 方法快三个数量级。Ren 等。[34] 该研究提出了一种基于物理原理的神经网络框架，通过训练前向卷积神经网络与逆向子神经网络，以替代 FWI . Rao 等人所采用的有限差分建模与迭代优化流程，从而实现对脑组织中肿瘤进行精确定量重建。

[35] Liu 等人提出了一种专为利用 FMC 对多层粘接复合材料中的缺陷进行定量检测而设计的全卷积网络（FCN）。[36] 开发了一种基于 UNet 的方法，充分利用由 FMC 表示的回波空间，以实现超分辨率极限及亚波长缺陷可视化。当.....时，数据驱动方法可能优于传统的基于物理原理的方法。

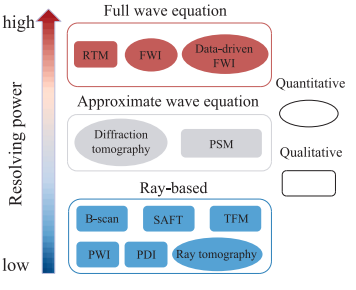



图 1。基于不同理论假设的声学成像方法。

训练数据与预测数据具有相似的分布特征；然而，即使训练数据与预测数据之间存在中等程度的分布偏移，也可能导致性能显著下降[37]。因此，尽管与基于物理的方法相比，数据驱动方法能够降低计算成本并缓解局部极小值问题，但其鲁棒性与泛化能力仍是值得进一步研究的领域。

近期，一种名为“神经算子”的新范式被提出，用于直接学习无限维函数空间之间的映射关系[38–40]。研究证明，神经算子具有强大的能力，可精确逼近非线性连续函数（从函数空间到实数的映射）以及非线性算子（从一个函数空间到另一个函数空间的映射）[38]，从而加速了天气预报[41]和二氧化碳封存[42]等领域的科学仿真与工程设计。在众多神经算子架构中，傅里叶神经算子（FNO）[40]采用快速傅里叶变换作为积分算子，通过数据学习傅里叶空间中的积分核；在一系列基准测试问题中，该算子相较于其他神经算子框架展现出更优的精度与计算效率[43]。与仅限于在离散网格上进行局部卷积的卷积神经网络（CNN）不同， FNO 利用全局神经积分算子来学习连续函数而非离散向量，如图 2所示。这一特性支撑了其强大的泛化能力、高精度以及对分辨率不变性的优势[40]；在波传播建模中，该算子能有效捕捉复杂的物理现象，例如非线性效应[44]、粘弹性[45]以及量子力学[46]。尽管神经算子在正向建模中具有上述优势，但将其应用于逆问题的研究仍相对较少。近期已有初步研究开始探索其在地震反演中的应用潜力。Lu 等人。[47] 将 FNO 作为解码器集成到 DeepONet 中，用于进行具有可变源参数的地震反演，这表明该方法对观测数据中的高斯噪声具有较强的鲁棒性。近期，Huang 等人提出了一种基于神经算子的 FWI 框架，该框架采用预训练的 FNO 作为代理前向模型[48]，并将波动方程约束整合到反演目标函数中，从而在保持计算效率的同时提升了重建质量[49]。

受这些研究进展的启发，我们进一步将神经算子范式拓展至超声波 NDT 领域，旨在利用相控阵FMC数据解决 FWI 中的高度不适定逆问题。我们提出一种U- FNO 框架，该框架在傅里叶域中整合核参数化方法以捕捉全局波缺陷相互作用，同时通过U-Net路径实现局部特征恢复。这一设计使得从包含散射、衍射及反射信号的FMC数据集到复杂介质中纵波速度分布的精确映射成为可能，从而显著提升逆问题求解的效率。与现有的数据驱动型 FWI 方法（如 InversionNet[30]）相比，U- FNO 在重建具有高对比度和复杂几何形状的缺陷时，具有更高的保真度和鲁棒性。

本文其余部分结构如下：第2节介绍了基于物理原理与数据驱动的 FWI 方法的相关背景信息，随后详细阐述了U- FNO 的设计方案；第3节展示了复杂几何缺陷反演成像实验结果，并对比了U- FNO 与InversionNet在重建精度和鲁棒性方面的表现；第4节利用实验数据对本文提出的方法进行验证，并将重建结果与InversionNet及 TFM 进行对比；第5节探讨了本方法的局限性及未来研究方向；最后，第6节对全文研究结论进行总结。

## 2. 方法

我们首先介绍了基于物理原理与数据驱动的全波形反演框架，随后详细阐述了用于 Unet Fourier 神经算子的网络框架。

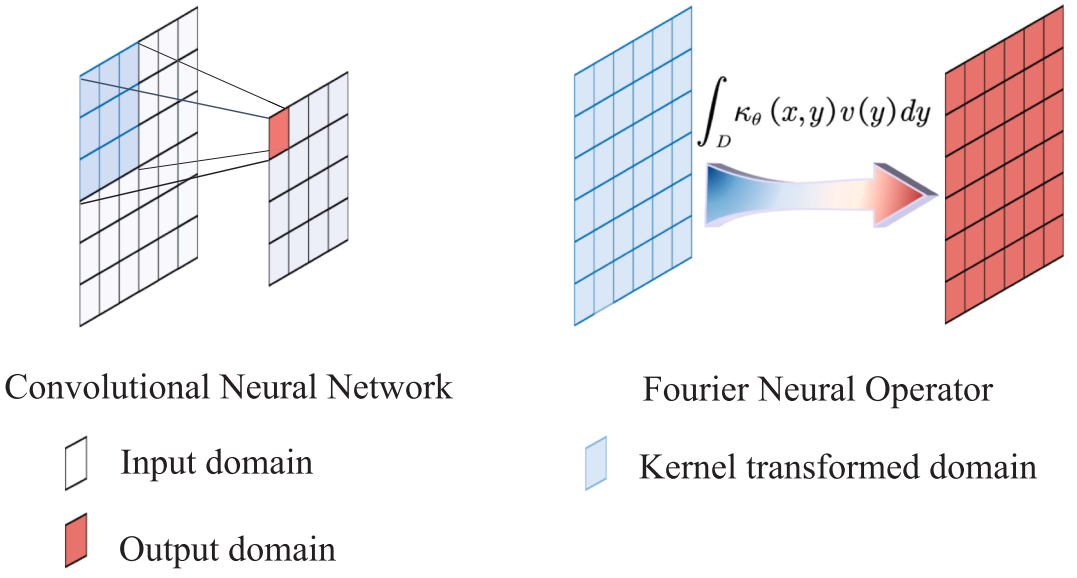



**图 2.**卷积神经网络（CNNs）与傅里叶神经算子之间的区别。

### 2.1. 基于物理原理的FWI

FWI 通常基于弹性波或声波方程，这些方程考虑了波在非均匀介质中传播的影响，并建立了传感器处观测到的波形数据与介质参数模型（例如：声速、密度及声阻抗）之间的关系，从而重建参数分布的图像。

二维波形正演建模能够精确描述波的传播过程，是波形反演算法的核心。在时域中，二维恒定密度各向同性声学波动方程可表示为如下形式：

$$\frac{\partial^2 u(x,y,t)}{\partial t^2} - \frac{1}{c(x,y)^2}\left(\frac{\partial^2 u(x,y,t)}{\partial x^2} + \frac{\partial^2 u(x,y,t)}{\partial y^2}\right) = s(x,y,t), \tag{1}$$

其中$u(x，y，t)$表示声压波场；$c(x，y)$代表二维声学介质中声速的空间分布，而$s(x，y，t)$为源函数。本文采用时域有限差分法（FDTD）求解波动方程[50]。

式(1)中所涉及的正向建模问题可简化为：

$$u = f(\boldsymbol{m}), \tag{2}$$

其中，$u$表示声压波场，$f$代表正向建模算子，$\boldsymbol{m}$为速度模型参数。反演过程始于一个给定的介质参数初始模型，随后通过正向建模获得该初始模型的合成波场；将实验测得的观测波场与合成波场之间的差异作为目标函数用于更新介质模型参数，从而收敛于一个能够生成与观测数据相符的合成数据的解。该反演过程的目标函数可表述如下：

$$E(\mathrm{m}) = \underset{\boldsymbol{m}}{\mathrm{m\ in}}\left(\left\|\mathrm{d} - f(\mathrm{m})\right\|_{22} + \lambda R(\mathrm{m}),\right) \tag{3}$$

其中$\boldsymbol{d}$为正向波形数据集，$\lambda$为正则化权重参数，$R(\boldsymbol{m})$表示正则化项。$\|\boldsymbol{d} - f(\boldsymbol{m})\|_{22}$表示数据不匹配的$L_2$范数。正则化项用于缓解基于物理原理的 FWI 方法所具有的不适定性，并稳定其收敛性。这种不适定性主要源于数据覆盖范围不完整以及参数间的串扰。通常，实验测量是在待测物体的边界上进行的，从而导致观测数据有限；此外，观测到的波场变化是由多个声学参数的耦合引起的，这使得难以准确解析各个声学参数对观测波场的贡献。模型参数的更新可表述为：

$$\boldsymbol{m}_{k+1} = \boldsymbol{m}_k - \alpha_k g_k, \tag{4}$$

其中$\boldsymbol{m}_k$表示第$k$次迭代的速度模型参数，$\alpha_k$为第$k$次迭代的步长，$g_k = \frac{\partial E(\boldsymbol{m}_k)}{\partial \boldsymbol{m}}$为第$k$次迭代的梯度。解决 FWI 问题通常采用伴随状态法计算梯度，这需要进行前向波传播、后向波传播以及时域内的全波场互相关运算[13]。该方法计算量大，达到收敛可能需要耗费大量时间。本文采用 Deepwave 方法，通过反向模式自动微分计算梯度，该方法在数学上等价于经典的伴随状态法[51]。研究表明，采用二阶优化方法通过计算目标函数中模型参数的Hessian矩阵可加速收敛速度[52]；然而，这些方法需要额外的计算资源。

### 2.2. 数据驱动型FWI（数据驱动直接反演法）

超声波检测（Ultrasonic FWI）旨在重建被测对象的声学参数分布，常用于检测金属材料中的缺陷（如孔洞或厚度方向裂纹）。这些缺陷可简化为声速异常区域（例如）。（孔洞内的空气，其中声速降至约 340 m/s）。通过将复杂的缺陷结构抽象为具有变化声速的非均匀介质，缺陷检测问题便转化为对高对比度声速模型进行逆向重构的问题。由于目标函数具有高度非线性、不适定性以及对初始模型的敏感性，传统的基于物理原理的 FWI 方法容易陷入局部极小值，且难以准确逆向重构高对比度模型——尤其是在缺乏低频信息或初始模型不可靠的情况下。相比之下，数据驱动方法通过将该问题转化为端到端的映射任务来应对这些挑战。数据驱动方法的核心思想是构建一个由速度模型$\boldsymbol{m}$与对应波形数据$\boldsymbol{d}$组成的配对数据训练集。该训练数据集随后用于训练一个深度神经网络，以学习从$\boldsymbol{d}$到$\boldsymbol{m}$的复杂非线性映射，从而能够直接根据在被测物体上实际观测到的数据来估计速度分布。这一方法可数学化表述如下：

$$\widehat{\boldsymbol{m}} = h_{\theta^*}(\boldsymbol{d}) \approx f^{-1}(\boldsymbol{d}),$$

$$s.t.\,\theta^*(.) = \underset{\theta}{\mathrm{argm}}在\sum_{(\boldsymbol{m}_i,\ \mathrm{di})\in} \mathbf{L}(h_{\theta}(\boldsymbol{di}),\ \boldsymbol{mi}), \tag{5}$$

其中$\theta$为神经网络的可训练参数，$h_\theta^*(.)$是参数为$\theta^*$的逆运算符，$\mathbf{L}(.,.)$表示损失函数，而 Φ 是包含配对样本 $(\boldsymbol{m_i}, \boldsymbol{di})$ 的训练数据集。与传统 FWI 方法相比，本方法的特点在于生成一组逆运算符而非单个模型逆运算。这意味着一旦训练完成，在更换重构对象时，得益于自适应大规模并行计算架构，神经网络能够快速推导出结果，无需进行重复迭代优化。

### 2.3. U- FNO 架构

傅里叶神经算子的目标是从有限的观测输入–输出数据对中学习两个无限维空间之间的映射关系。在超声波 FWI 应用中，U- FNO 用于从速度模型$\boldsymbol{m}$与FMC $\boldsymbol{d}$的配对数据集出发，学习等式(5)所描述的逆算子映射。对于等式。(5)，我们采用 L1 范数作为损失函数。

我们将输入函数在有限维空间中进行离散化，具体计算每个预设的激励器位置$D_E = \{x_1, x_2, x_3 \cdots x_E\}$， $D$以及表面接收器位置$D_R = \{x_1, x_2, x_3 \cdots x_R\}$， $D$，每个接收器在$T$时刻记录$D_T = \{t_1, t_2, t_3 \cdots t_T\}$， $D$个样本。因此，每个激励器对应的离散超声波数据构成一个形状为 $(T, R)$ 的矩阵；所有观测到的离散数据则构成一个形状为 $(T, R, E)$ 的张量。U- FNO 的输出 m 是一个空间域上的函数，因此也需要在有限维空间中进行离散化。我们将在位置 W × H 处计算$\boldsymbol{m}$，其中 W 和 H 分别对应速度场的水平范围和垂直范围。

U- FNO 采用迭代式架构设计。

$$G_\theta: \boldsymbol{d} \mapsto z_0 \mapsto z_1 \mapsto \ldots \mapsto z_{N-1} \mapsto \boldsymbol{m}, \tag{6}$$

其中，对于 j = 0,1 ，...，$N$- 1，$z_j$是一个函数序列。综合考虑计算效率与性能之间的平衡，我们在 U- FNO（图 3(a)）中采用了一个傅里叶层（图 3(b)）和两个 U-傅里叶层（图 3(c)）。

首先，输入观测数据 d 通过线性变换 P 被映射到一个更高维的空间中。

$$z_0 = P(\boldsymbol{d}) \in \mathbb{R}^{T \times R \times C}, \tag{7}$$

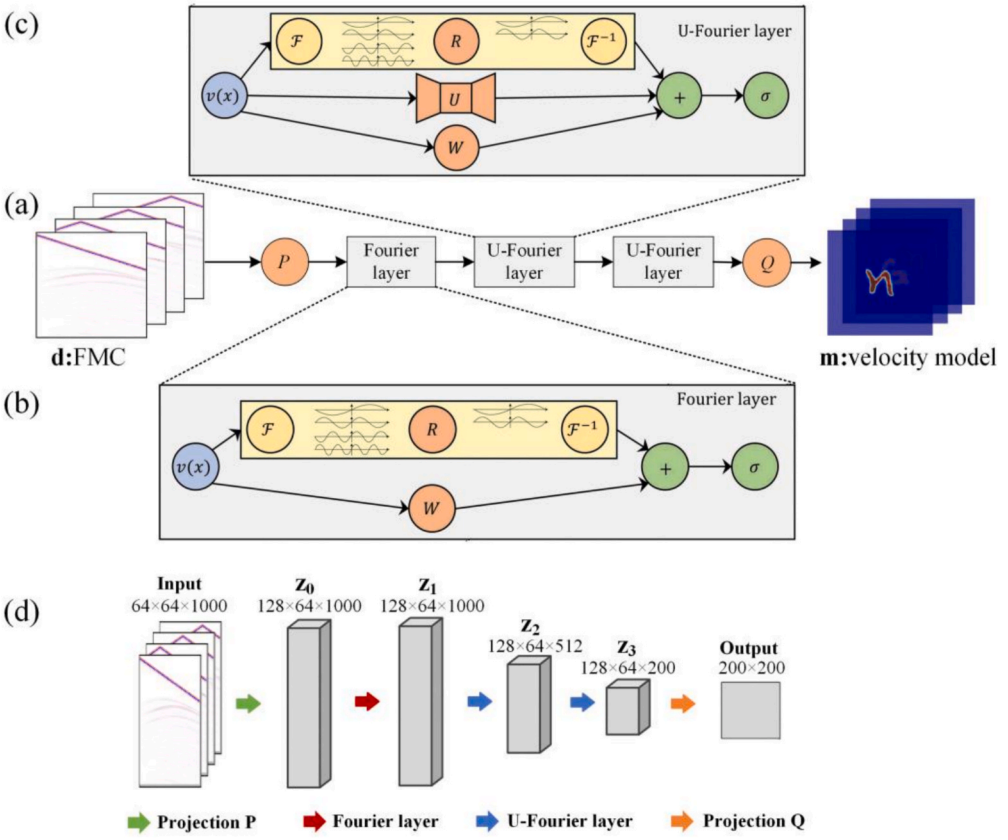



**图 3.**(a) U- FNO 模型架构。$\boldsymbol{d}$为输入，$P$与$Q$为全连接神经网络，$\boldsymbol{m}$为输出。(b) 傅里叶层，改编自[40]。(c) U-傅里叶层，改编自[53]。(d) 输出形状。$z_j$，$j$= 0,1,2,3

其中 C 表示隐藏通道数，用于控制所学习算子对应的潜在特征空间的维度；$z_0$表示经过线性层后的输出。我们通过映射一个维度为 T × 1 的函数来生成速度场$\boldsymbol{m}$。然而，傅里叶层与 U-Net 层的输入和输出维度相同。为实现这一维度转换，我们在每个傅里叶层及 U-傅里叶层的激活层之前均添加了一个线性层。

接下来，我们采用一个傅里叶层和两个 U-傅里叶层构成一个合并网络：

$$\begin{aligned} z_1 &= \sigma(W_0(\mathrm{K0}(a;\,)z0 + \mathrm{W0}\,z_0)), \\ z_2 &= \sigma(\mathrm{W}_1(\mathrm{K1}(a;\,)z1 + \mathscr{U}_1 z_1 + W_1 z_1)), \\ z_3 &= \sigma(W_2(\mathrm{K2}((a;\,)z2 + \mathscr{U}_2 z_2 + W_2 z_2))), \end{aligned} \tag{8}$$

其中$z_1$，$z_2$与$z_3$分别对应于文中所述的傅里叶变换、U-Fourier 1 以及 U-Fourier 2 的输出结果。表 1。$W_i$与$W$、$_i$均为线性变换；$\mathscr{U}_i$为 Unet CNN 算子；$_{\epsilon}$ 为非线性激活函数；$\mathscr{K}_i$（$a$；$_{\cdot}$ ）是由神经网络参数化的核积分变换参数。这在神经算子中具体描述如下：

$$\left(\mathscr{K}(a,\theta)z_j\right)(x) = \int_D \kappa_\theta(x-y,a)z_j(y)dy, \forall x \in D. \tag{9}$$

FNO 方法的主要特点在于：它通过直接对傅里叶空间中的积分核进行参数化，来构建算子学习任务。该积分核采用快速傅里叶变换（FFT）进行表示，具体表达式为：

$$(\mathbf{K}(\mathrm{a},\,)z_j)(\mathrm{x}) = \mathbf{F}^{-1}(\mathbf{F}(\,)\cdot\mathscr{F}(z_j))(\mathrm{x}) = \mathbf{F}^{-1}(R_{\theta}\cdot\mathscr{F}z_j)(\mathrm{x}), \tag{10}$$

其中$\mathbf{F}$表示一个二维 FFT，$\mathbf{F}^{-1}$为其逆矩阵。$R_\theta$是周期函数 $_\theta$:$\overline{D}$ ↳ $\mathrm{R}^{d_z\times d_z}$（该函数由 参数化）的傅里叶变换。注意 $_\theta$是一个可进行傅里叶级数展开的周期函数，适用于傅里叶变换的离散模式$k\,\mathrm{W}\,\mathrm{Z}^{d}$。首先，我们将其截断至最大模态数$k_{\max} = |Z_{k\max}| = \{k\,\mathrm{W}\,\mathrm{Z}^{d}: |k_n| \le k_{\max},\ _j,\ \text{对于 n = 1，...，}d\}$，然后直接将$R$参数化为形状为 $(k_{\max}\times d_z\times dz)$ 的复值张量，此时截断后的傅里叶系数使得 从我们的记号中移除。与权重张量$R$相乘即为

$$\left(R\cdot\left(\mathscr{F}z_j\right)\right)_{k,l} = \sum_{i=1}^{d_v} R_{k,l,n}(\mathscr{F}v_t)_{k,n}, k = 1,\ldots,k_{\max}, n = 1,\ldots,d_v. \tag{11}$$

在实际应用中，我们发现将$k_{\max}$设为 40 对于我们所考虑的所有任务均足够。如需了解更多关于 FNO 的详细信息，请参阅[40,53]。这表明网络参数是在傅里叶空间中定义并学习的，而对应于输出函数傅里叶级数表示的系数则是从数据集中推断得出的。这一离散不变性特性还支持零样本超分辨率技术[40]。

与传统的傅里叶层不同，U-Fourier层整合了Unet路径。由于傅里叶基函数被截断为有限个数，该傅里叶层赋予了网络抗噪能力；然而，这可能会导致数据中高频信息的丢失。相比之下，Unet路径可通过在结构化网格上利用局部卷积对数据进行处理[53]，从而增强网络架构在高频段的表征能力。

最后，应用非线性变换 Q 将最终 U-Fourier 层的输出 z 3 映射至速度模型。

$$\boldsymbol{m} = Q(z_3) \in \mathbb{R}^{W\times H\times 1}. \tag{12}$$

U- FNO 的运算细节与结构详见表 1，其详细流程则在算法 1 中予以阐述。

**算法 1：适用于 FWI 的 U- FNO**

**输入**：$d$：FMC数据集，$\boldsymbol{m}$：真实速度模型，$\boldsymbol{m}$：预测速度模型，$N$：训练集数量，$E$：训练轮数，$I$：每个训练轮次中更新速度模型的迭代次数，$B$：批量大小，$lr$：训练学习率

步骤 1：采用参数为 的 U- FNO 框架来近似逆算子。

步骤 2：基于训练数据集生成二维速度模型

步骤3：通过有限差分法求解等式(3)以合成FMC数据

（下一页继续）

**表1**

U- FNO 架构：该合并网络包含一个傅里叶层和两个U-傅里叶层。

| | 操作 | 输出形状 |
|---|---|---|
| 投影 P | 线性 | (128,64,1000) |
| 傅里叶层 | 相加（Fourier2d + Conv1d），ReLU | (128,64,1000) |
| U-Fourier 第 1 层 | 组合（Fourier2d + Conv1d + UNet2d）、线性层、ReLU | (128,64,512) |
| U-Fourier 第 2 层 | 组合（Fourier2d + Conv1d + UNet2d）、线性层、ReLU | (128,64,200) |
| 投影 Q | Permute、线性、ReLU、线性、ReLU、 | (64,200) |

| | |
|---|---|
| Permute、线性、ReLU、线性 | (200,200) |

（续

| **算法 1：适用于 FWI 的 U- FNO** |
| --- |
| 步骤 4：将所有数据对输入到网络中，并使用 Adam 算法更新超参数。 |
| **对于**$ e = 1，\dots. *E*，**执行** |
| **对于**$ b = 1，\dots. *B*，**执行：** |
| **对于**$ n = 1，\dots. *I*，**执行** |
| 从ˇ 中抽取的样本训练对 (***m**i*，***di***) |
| 将输入***d**i*输入到网络中，根据等式(6)计算出 ^***m**i*<br>根据等式(5)计算损失值。 |
| 使用 Adam 优化器更新参数 ，其中*lr*为学习率：， *m*+1=， *m* −*lr* ŷ *θ***L**(， *m*) |
| **结束** |
| **结束** |
| **结束** |

### 2.4. 影像学检查结果的质量评估

本文采用结构相似性指数（SSIM）、均方根绝对误差（MAE）、均方根误差（RMSE）以及$L^2$相对误差对逆向成像质量进行定量评估。 SSIM 根据亮度、对比度和结构三个维度衡量两幅图像之间的差异，从而更准确地反映人眼的直观感知[54]：

$$\mathrm{SSIM}(\mathrm{x},\mathrm{y}) = \frac{\left(\right)\left(2\mu_x\mu_y + C_1\right)\left(2\sigma_{xy} + C_2\right)}{\left(\mu_x^2 + \mu_y^2 + C_1\right)\left(\sigma_x^2 + \sigma_y^2 + C_2\right)}, \tag{14}$$

$$\mathrm{MAE}(x,y) = \frac{1}{n}\sum |y - x|, \tag{15}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum (y - x)^2}, \tag{16}$$

$$L_2 = \frac{1}{n}\sum \left|\frac{y - x}{y}\right|, \tag{17}$$

其中$n$表示样本数量。， $x$、$\mu$ $y$、， $x$、， $y$以及， $xy$分别表示图像$x$与$y$的局部均值、标准差和交叉协方差。正则化常数$C_1$= 10 −4与$C_2$= 9 × 10 −4可避免在局部均值与标准差接近零时出现数值不稳定性。因此，较大的 SSIM 、较小的 MAE、 RMSE 及$L_2$相对误差表明速度重建效果更优。

## 3. 数值实验

### 3.1. 仿真设置

扩展版美国国家标准与技术研究院（EMNIST）数据集包含源自 NIST 特殊数据库 19 的手写数字字符，这些字符已被转换为 28 × 28 像素的图像格式[55]。该数据集是机器学习领域的核心基准数据集，尤其因其丰富的结构多样性与视觉复杂性而备受关注。基于上述特性， EMNIST 数据集在计算成像任务中得到了广泛应用，例如电磁后向散射[56]和超声成像[57]；在这些任务中，该数据集常用于评估模型在处理复杂散射体或目标时的性能。在本研究中，采用 EMNIST 模式系统性地生成几何结构多样且拓扑结构复杂的速度分布。这一基准数据集具有超越简单参数化包含体的显著结构多样性特征，能够对用于重建复杂散射体的反演框架进行严格评估，并全面衡量其定量反演能力、鲁棒性及泛化性能。

我们基于 EMNIST 数据集中的字母子集构建了一个声速模型数据集；该子集仅包含 26 个大写和小写字母的手写样本，不包含数字字符。为满足正向建模对空间分辨率的要求，对每幅 28 × 28 像素的图像进行了零填充处理，并将其分辨率扩展至 200 × 200 像素。这些高分辨率二值图像随后被映射至声速分布图中，其中像素强度值被线性转换为范围在 1500 m/s 至 5800 m/s 之间的声速值。这种映射方式使得每个像素都能代表声学特性的局部变化，从而有效模拟工业检测场景中常见的复杂内部缺陷分布模式。共构建了 6000 个声速模型；其中 4500 个用于神经网络的训练，500 个作为验证集，剩余 1000 个样本用于测试目的。 EMNIST 数据格式确保了每个样本均具有唯一性且相互独立。

为生成网络训练所需的配对数据集（$m$，$d$），通过采用基于等式(1)的交错网格有限差分法求解声波方程，进行了正向波场模拟。计算域采用二阶时间精度和八阶空间精度进行离散化，空间网格步长为 0.2 mm，以确保数值稳定性。

精度[50]。整个计算域尺寸为 40 × 40 mm。此外，在侧边边界处采用了完美匹配层（PML）以消除人工反射。如图 4所示，一个由 64 个单元组成的线性相控阵（单元间距为 0.6 mm）沿模型表面布置。每个阵元依次激活，发射一个中心频率为 2.25 MHz 的 Ricker 波包，而所有阵元同时记录由此产生的波场。对于每次发射，采集 1000 个时间样本，从而得到一个尺寸为 64（发射器）× 64（接收器）× 1000（时间步长）的最终数据立方体。该全矩阵采集（FMC）数据集包含了关于由复杂内部结构引起的散射波场的丰富信息。时间步长设定为 2 × 10ӥњ s，总模拟时间为 2 × 10ӥ ї s。需注意的是，本研究仅激发并记录纵波，未考虑纵波与横波之间的潜在模态转换。

### 3.2. 逆变换结果

为评估所提出的 U- FNO 网络，我们采用 InversionNet 作为基线模型。InversionNet 采用一个由编码器和解码器组成的全卷积网络（FCN）来执行反演过程；该方法已被证明是一种有效的地震反演方法，在多个基准数据集上取得了业界领先的性能。上述两种方法均基于 PyTorch 1.13 框架在 Python 3.9 环境下编写，并使用 Adam 优化器进行训练，其参数配置与表 2所示一致。在训练和测试阶段，观测数据及速度模型均被归一化至 −1 至 1 的范围内。所有实验均在一台配备 NVIDIA RTX A6000 显卡（48 GB）及 Intel 4210R 中央处理器（CPU）的计算机上完成。

图 5(a)、(d) 和 (g) 展示了从测试集中随机选取的三个真实速度模型。图 5(b)、(e) 和 (h) 为 U- FNO 的反演结果，表明 U- FNO 能够准确重建不同缺陷的几何形状。图。图 5(c)、(f) 和 (i) 展示了 InversionNet 的反演结果；该模型能够大致重建缺陷的几何形态，但在细节处会产生冗余的异常区域。这表明 InversionNet 在处理其未曾见过的新样本时，其重建结果可能存在不准确性。为便于更清晰地进行对比，本文将图 5(a–i) 中在水平位置 x = 21 mm 处提取的垂直速度剖面进行对比，并展示于图 5(j–m) 中。图 5(j–m) 展示了真实值（黑色）、U- FNO（蓝色）以及 InversionNet（红色）预测的垂直速度剖面。

在几乎所有情况下，采用本文提出的方法所预测的剖面值都更接近真实流速值，且在空间位置上更为一致。此外，图 6展示了不同方法在测试集上的重构误差分布情况，表明 U- FNO 在捕捉观测数据中固有的复杂时空关系方面具有更优越的性能，因此其精度优于 InversionNet。此外，用于在测试集上评估不同方法的定量指标（包括 SSIM 、MAE、 RMSE 以及$L^2$相对误差）列于表 3中。数值结果表明，U- FNO 的预测结果具有更小的 MAE、更小的 RMSE 、更小的$L^2$相对误差以及更大的 SSIM ，这表明该方法比基线方法具有更高的准确性和泛化能力。

为与传统 FWI 方法进行公平对比，本研究采用Deepwave[51]在与所提方法相同的数值设置及GPU平台下开展反演实验，从而确保计算配置与硬件环境的一致性。图7(a)–(c)展示了与上述情况对应的真值速度模型。

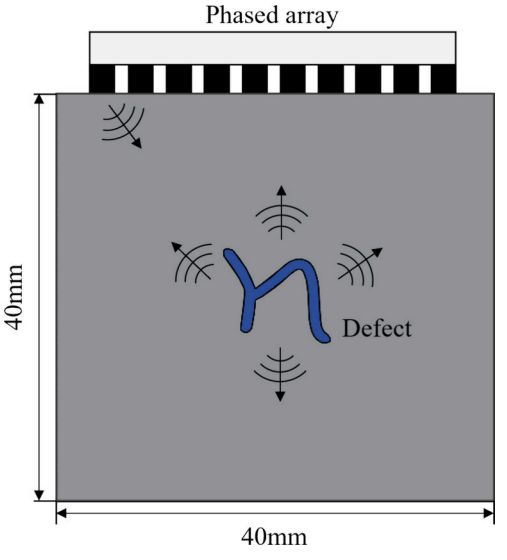



**图 4。**一幅描绘速度模型的示意图，其中棕色方块表示源点与接收点的位置，而蓝色结构则表示基于 EMNIST 字母数据集生成的复杂几何缺陷模型。（如需了解本图例中对颜色标注的解读，请参阅本文的网络版。）

**表 2**
网络训练配置。

| 模型 | 批量大小 | 学习率 | 样品 | 迭代次数 | $k_{max}$傅里叶模态（截断阶数） |
|---|---|---|---|---|---|
| U-FNO | 32 | $1e^{-3}$ | 4500 | 60,000 | 40 |
| Net 版本 | 32 | $1e^{-3}$ | 4500 | 60,000 | |

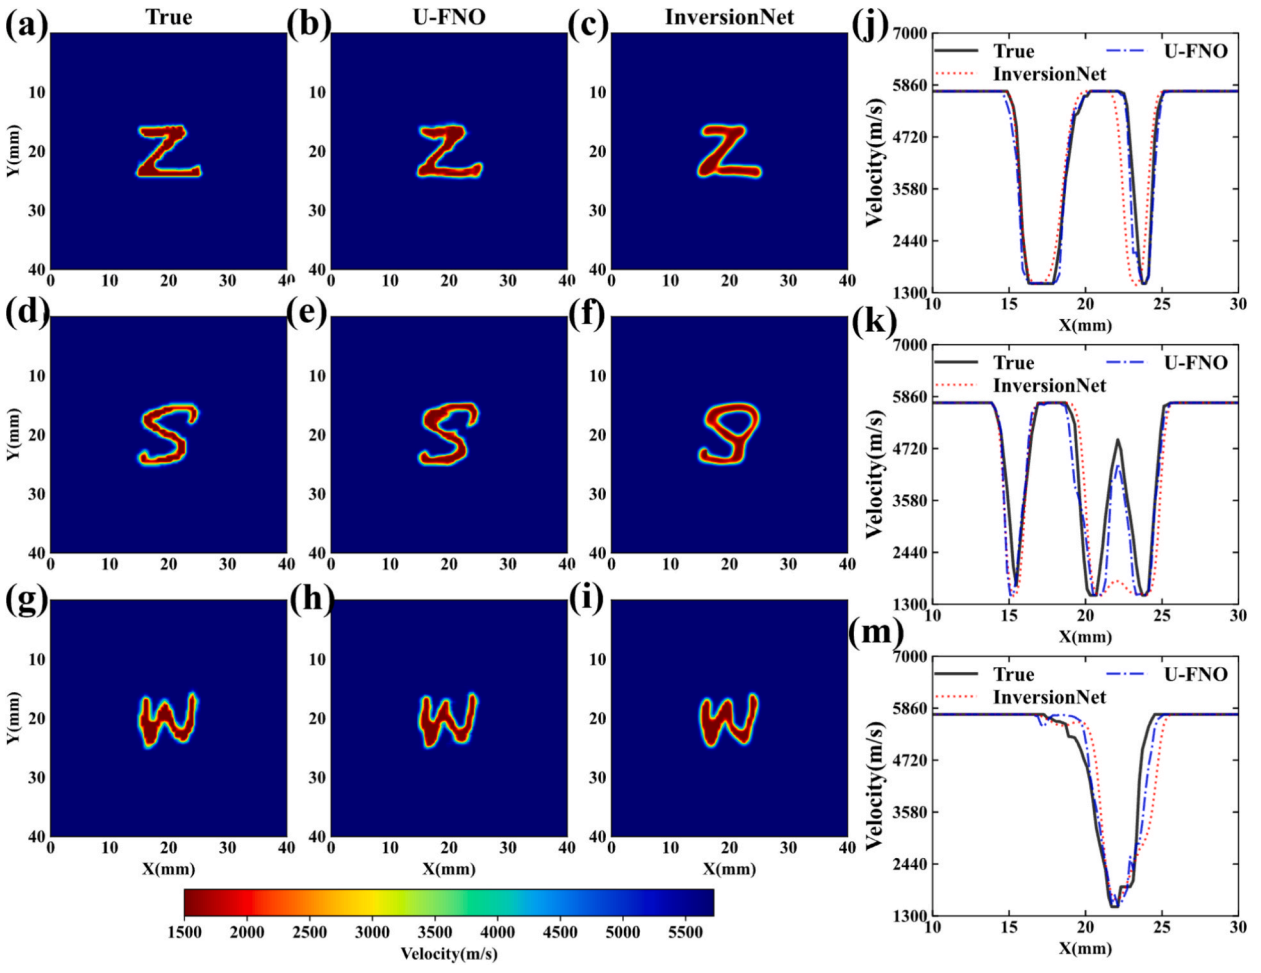



**图 5.**携带复杂几何缺陷的速度模型经 U- FNO 和 InversionNet 逆演得到的结果。(a)、(d) 和 (g) 分别显示了用于逆演的真实模型；(b)、(e) 和 (h) 分别显示了对应于 (a)、(d) 和 (g) 的 U- FNO 逆演结果；(c)、(f) 和 (i) 分别显示了对应于 (a)、(d) 和 (g) 的 InversionNet 逆演结果；(j)、(k) 和 (m) 分别展示了从真实模型、U- FNO 逆演结果及 InversionNet 逆演结果中提取出的位于 x = 21 mm 处的一维速度剖面。

参数配置如图 6(a)、(d) 和 (g) 所示。图 7(d)–(f) 展示了从均匀初始模型获得的 FWI 重构结果。对于高对比度速度分布情况，当从均匀模型进行初始化时， FWI 重构法无法收敛至真实速度模型。相比之下，所提出的框架在相同的实验条件下能够实现稳定且精确的图像恢复。表4总结了 FWI 、InversionNet与U- FNO 在训练时间与推理时间方面的对比结果。结果表明，与传统的 FWI 方法相比，基于神经算子的逆向方法在离线训练阶段需要更高的计算成本；然而，一旦完成训练，所学习到的逆算子便能为在相似测量配置下采集的图像数据集实现显著更快的重建速度。

### *3.3. 噪声对反演的影响*

考虑到现实场景中噪声普遍存在，本研究探讨了噪声对所提方法的影响。在图 5(g) 所示的速度模型观测数据上，分别添加了 SNR 为 6 dB 和 20 dB 的高斯噪声，作为两项测试。

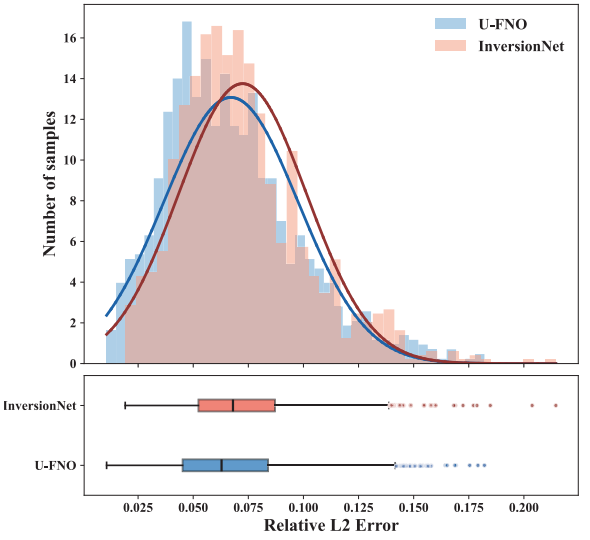



**图 6.**1000 个测试样本的重构误差分布。

**表 3**

基于 1,000 个测试样本对不同模型反演结果进行定量评估的指标。

| 模型 | MAE | RMSE | SSIM | $L^2$相对误差 | 测试时间 |
|---|---|---|---|---|---|
| U-FNO | 0.008466 | 0.0666 | 0.989006 | 0.06824 | 49 s |
| Net 版本 | 0.008751 | 0.07078 | 0.987948 | 0.07379 | 26 s |

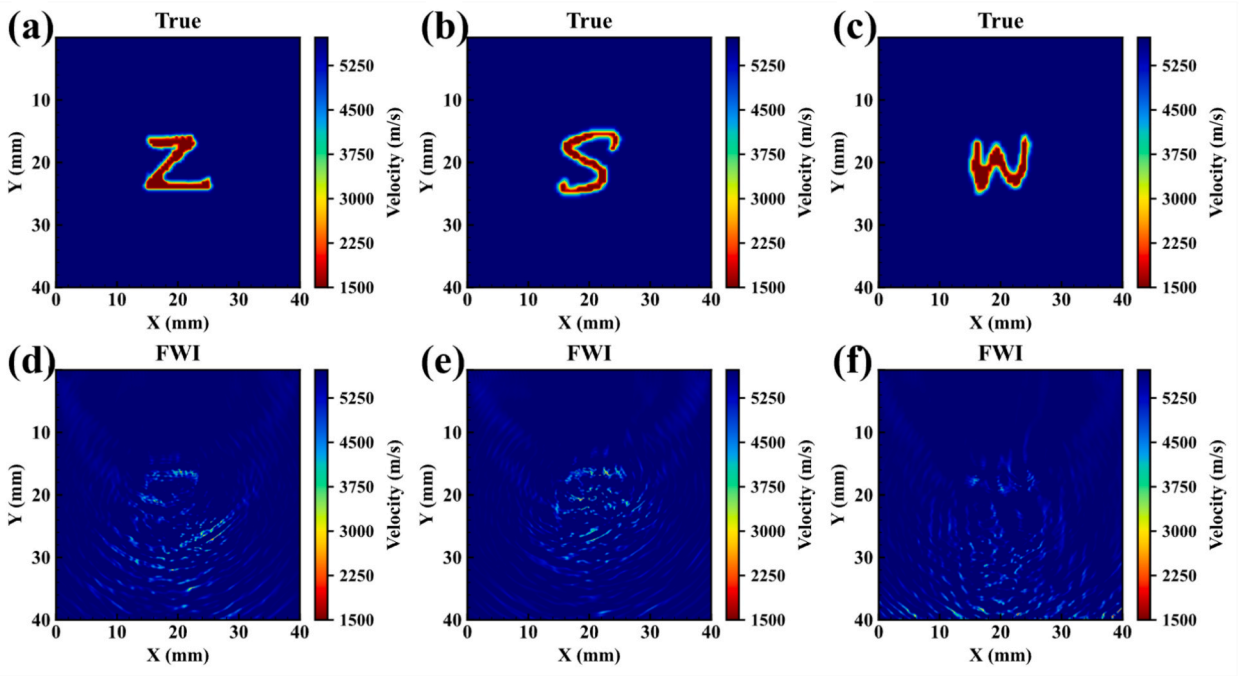



**图 7.**具有复杂几何缺陷的速度模型的 FWI 逆演结果。(a)、(b) 和 (c) 分别展示了用于逆演的真实模型；(d)、(e) (f)分别展示了与(a)、(b)及(c)相对应的 FWI 逆变换结果。

**表4**

FWI 、InversionNet 与 U- FNO 之间的训练与推理时间对比。

| 模型 | 迭代次数 | 训练时间/迭代次数 | 每次重建的推理时间 |
|---|---|---|---|
| U-FNO | 60,000 | 1.809 s | 0.049 s |
| Net 版本 | 60,000 | 1.059 s | 0.026 s |
| FWI | 100 | 72.75 s | 7275 s |

样本随后被输入到网络中。需要特别注意的是，在对观测数据添加噪声时无需进行重新训练。图 8展示了 U- FNO 与 InversionNet 对两个测试样本的反演结果。真实速度模型如图 8(a) 和 (d) 所示，而图 8(b) 和 (c) 分别展示了 U- FNO 对信噪比（SNR）为 20 dB 和 6 dB 的观测数据所得到的反演结果。这表明，所提出的方法在中等噪声水平下仍能保持可接受的重建质量。图。图 8(e) 和 (f) 分别展示了 InversionNet 对信噪比（SNR）为 20 dB 和 6 dB 的观测数据所得到的反演结果；这表明当噪声水平较低时，该网络能够近似重建缺陷的几何形状；然而，当噪声水平达到一定阈值时，重建结果将变得显著失真。类似地，图 8(g) 展示了在 y = 21 mm 处重建图像的垂直速度剖面对比结果。表 5列出了单个模型在不同 SNR 水平下反演结果的定量指标，包括 SSIM 、MAE、 RMSE 以及$L^2$相对误差。在 SNR 为 6 dB 的测试集上，不同方法所得重建误差的分布情况如图 9所示。这些结果表明，所提出的方法具有更强的鲁棒性和稳定性。

## 4. 实验验证

### *4.1. 实验装置*

所提出的方法随后通过实验进行了验证，并与基准模型进行了对比；该实验设置与仿真结果大致吻合。如图所示。10，该实验装置采用Pioneer相控阵采集系统（The Phased Array Company），该系统配备64个完全独立的通道，可实现高保真信号采集及对每个阵元的精确控制。该设备连接至一台线性相控阵探头（2.25 MHz-128个单元，imasonic，法国），其中心频率为2.25 MHz，单元间距为0.6 mm。实验采用三个尺寸为150 × 40 × 30 mm（纵波速度为5724 m/s）的Hastelloy C-276试样。作为典型的固溶强化镍基高温合金，Hastelloy C-276因其优异的抗氧化性、耐腐蚀性和耐高温性而广泛应用于核能及石油化工领域[58]。复杂几何缺陷的制备通过线切割技术实现；这些缺陷的构型可参考图11(a)、(d)和(g)，这些缺陷采用样条曲线自由设计，以确保其与训练集不同。将三个试样浸入水浴中以建立

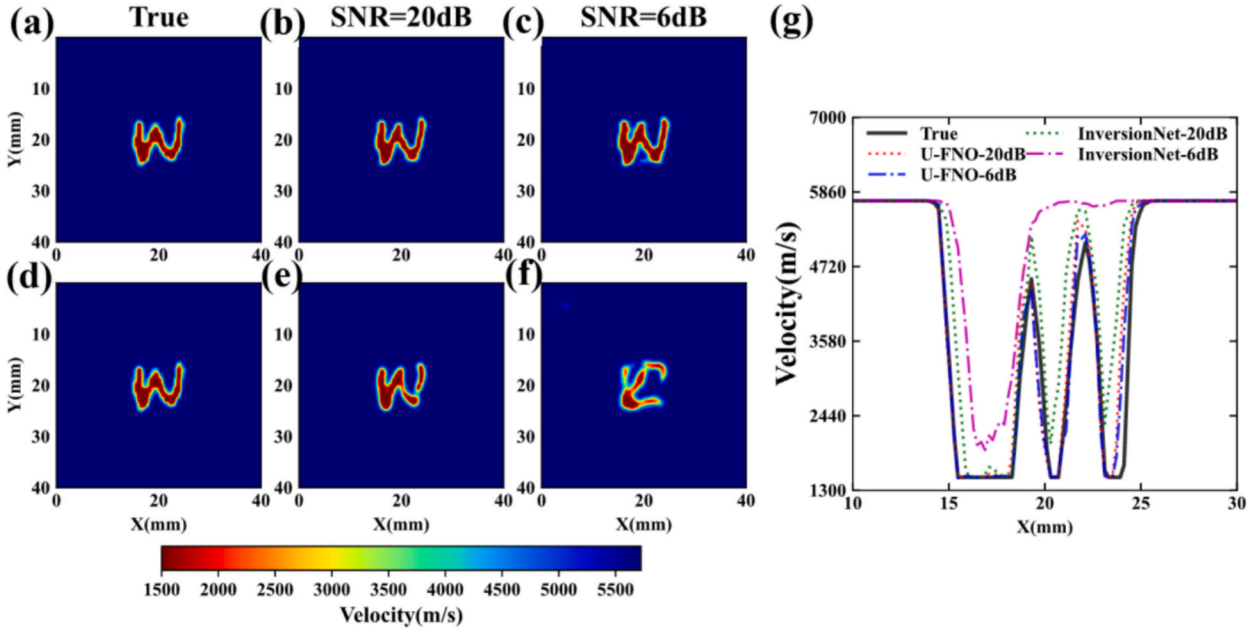



**图 8。**图 5(g) 中 U- FNO 与 InversionNet 对速度模型进行反演所得的结果：(a) 和 (d) 展示了用于反演的真实模型；(b) 和 (c) 分别展示了信噪比（SNR）为 20 dB 和 6 dB 信号的 U- FNO 反演结果；(e) 和 (f) 分别展示了信噪比为 6 dB 和 25 dB 信号的 InversionNet 反演结果；(g) 展示了从真实模型 UFNO 以及 InversionNet 反演结果中提取出的 y = 21 mm 位置处的一维速度剖面。

**表5**

针对观测数据中具有不同信噪比（SNR）的单个样本所获得的反演结果的定量指标。

| 模型 | SNR | MAE | RMSE | SSIM | $L^2$相对误差 |
|---|---|---|---|---|---|
| U-FNO | 20 dB | 0.007482 | 0.047775 | 0.991512 | 0.054616 |
| | 6 dB | 0.009676 | 0.057599 | 0.987443 | 0.065848 |
| Net 版本 | 20 dB | 0.010650 | 0.073255 | 0.985376 | 0.083746 |
| | 6 dB | 0.032916 | 0.177602 | 0.955610 | 0.203037 |

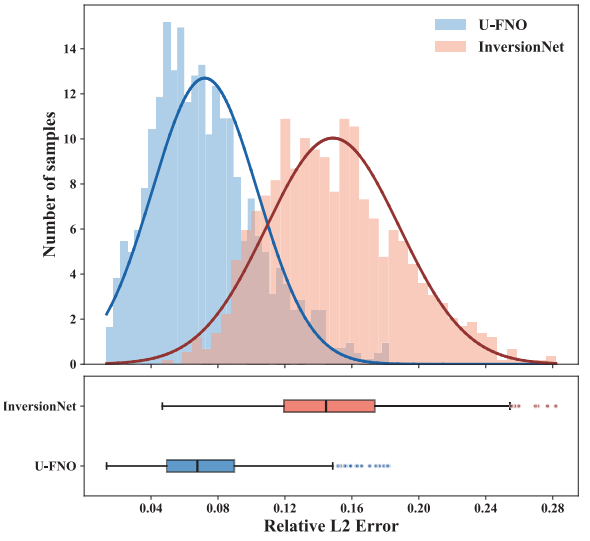



**图 9.**在 6 dB SNR 条件下，1000 个测试样本的重构误差分布。

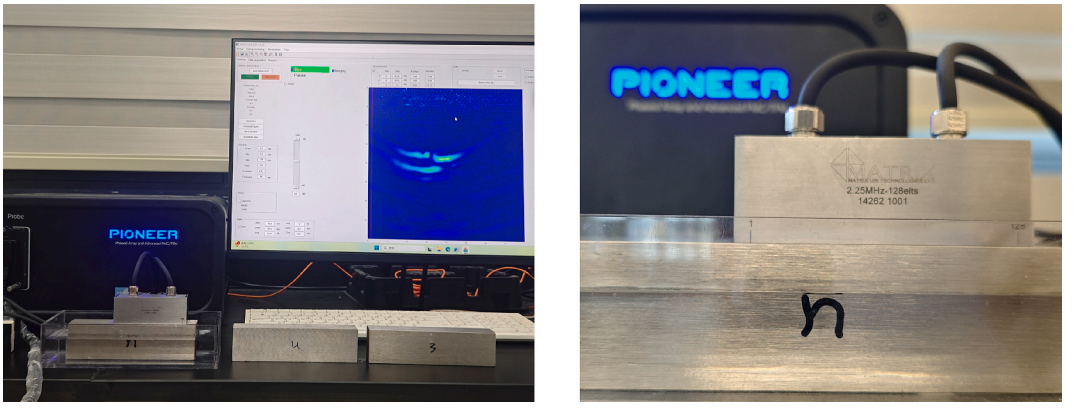



**图 10。**实验装置由 Pioneer 相控阵采集系统、一台线性相控阵天线及三个试样组成。

界面间的声学耦合使得声波在缺陷内部发生多次散射，从而增强缺陷信息，如图 10所示。采用频率为 2.25 MHz 的 Ricker 波作为激励信号，阵列数据通过 FMC 进行记录。请注意，仅使用了第 1–64 通道。

### *4.2. 逆变换结果*

实验中采集的三个测试试件的 FMC 数据被用作网络的输入，其反演结果如图 11所示。图。图 11(a) 与 (d) 展示了两个穿过具有与训练样本相似特性的参数化实验试件的实测速度场模型；图 11(b) 与 (e) 为 U- FNO 方法的反演结果；图 11(c) 与 (f) 展示了 InversionNet 方法的反演结果；此外，图 11(j) 与 (k) 给出了在 y = 21 mm 处重建图像的水平速度场剖面对比结果。上述结果表明，所提方法的实验结果与仿真结果吻合良好。

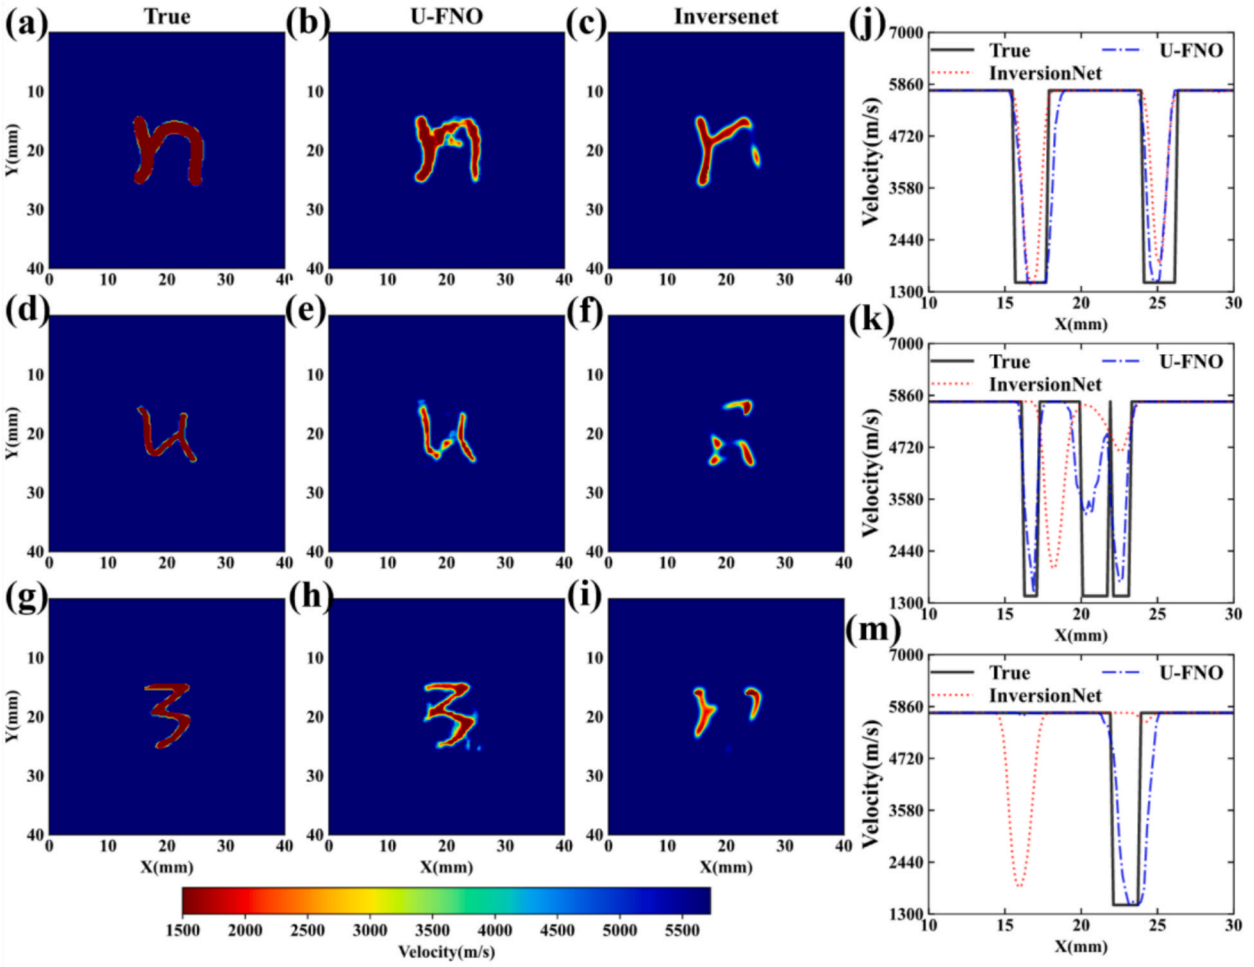



**图 11.**在实验室中对具有复杂几何缺陷的参数化试验试件进行 U- FNO 和 InversionNet 逆问题求解的结果。(a)、(d) 和 (g) 展示了用于逆问题求解的真实模型；(b)、(e) 和 (h) 分别展示了对应于 (a)、(d) 和 (g) 的 U- FNO 逆问题求解结果；(c)、(f) 和 (i) 分别展示了对应于 (a)、(d) 和 (g) 的 InversionNet 逆问题求解结果；(j)、(k) 和 (m) 分别展示了从真实模型、U- FNO 逆问题求解结果以及 InversionNet 逆问题求解结果中提取出的 y = 21 mm 位置处的一维速度分布曲线。

该方法能够实现对高对比度声速模型的高精度重建；相比之下，InversionNet 仅能重建部分缺陷几何结构。由于这两种网络模型共享相同的训练样本和训练策略，准确的反演结果表明，所提出的傅里叶层与 U-傅里叶层对缺陷速度模型的精确重建起到了重要作用。具体而言，傅里叶有限群截断所引入的正则化效应可增强模型的鲁棒性、稳定性及泛化性能。此外，Unet网络架构能够通过捕获丢失的高频特征，实现对缺陷细节更精确的恢复。

尽管所提方法能够准确重建整体缺陷几何形状，但在预测速度模型中仍可观察到残余定量误差及局部伪影。一种可能的原因在于，该方法基于声波方程构建，这意味着在训练过程中未考虑实验数据中所包含的剪切波及模态转换信息，导致这些信息被误判为缺陷或声速异常。需注意的是，尽管弹性波方程比声波方程更适用于描述材料行为，但声波方程可为弹性波方程提供一个良好的运动学L波近似解，这不仅降低了计算成本，还便于逆问题求解算法的实施[35]。此外，对训练超参数进行进一步调整以及对实验信号进行更精确的校准，也将提升成像性能。这些课题将作为本项工作的未来研究方向。

图 12展示了 TFM 方法基于三个试件的实验测量数据生成的定性图像。这些 TFM 图像对缺陷中波首次到达处进行了适度显示，其位置与所提方法的反演结果基本一致；然而，该方法无法对缺陷的整体几何形状进行重建。这是因为 TFM 方法基于射线近似法，未能充分利用由波的衍射和散射效应所提供的额外缺陷信息。值得注意的是，基于 U- FNO 的超声波 FWI 方法能够实现对 L 波速度的定量重建，而 TFM 方法仅能恢复以分贝为单位的信号幅值。

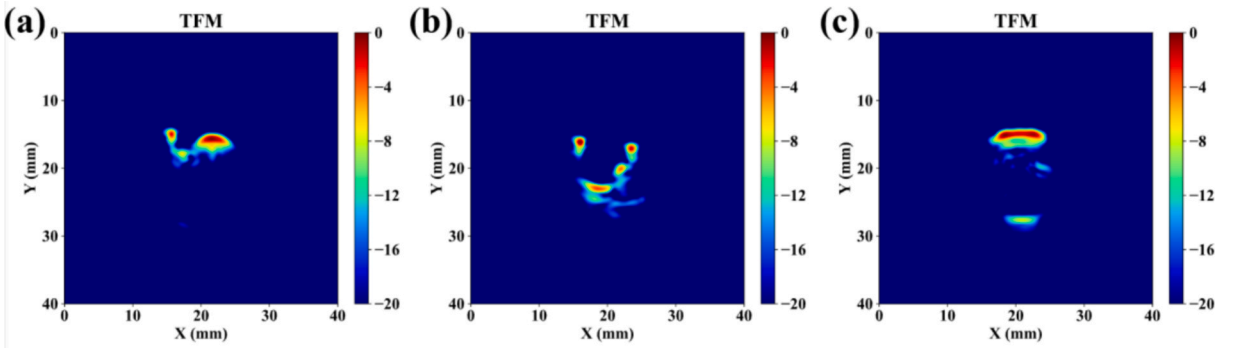



**图 12.**传统 TFM 图像。(a) 与图 11(a) 所示模型对应的 TFM 结果；(b) 与图 11 所示模型对应的 TFM 结果。
(d) (c) TFM 与图 11(g) 所示模型对应的计算结果。

### *4.3. 泛化能力*

泛化能力是数据驱动型全波形反演方法中一项至关重要的但极具挑战性的要求——它为整个样本集而非单次反演过程提供了一个逆算子。为验证该网络在基于 EMNIST 字母集构建的训练数据集中的泛化能力，研究专门设计了一个数字化几何缺陷样本（如图 11 (g)、(h) 和 (i) 所示），这些图分别对比了 U- FNO 与 InversionNet 的反演结果。研究结果表明，所提方法在准确预测样本内部结构及识别缺陷方面具有显著成效，且其在速度模型上的泛化能力超越了训练数据集所涵盖特征范围的限制。必须强调的是，所提出的方法不仅关注缺陷几何形状的重建，更致力于揭示 FMC 与介质速度分布之间复杂的非线性映射关系。该缺陷被定义为一个速度异常区域，在数据驱动的 FWI 方法中，整个试样被视为一个非均匀介质。

## 5. 讨论与局限性

本研究表明，所提出的 U- FNO 方法在包括 MAE、 RMSE 、 SSIM 以及$L^2$相对误差在内的多项指标上均优于 InversionNet 方法，测试数据来自公开可用的 EMNIST Letter 数据集。尽管两种方法在无噪声仿真数据上表现相当，但在存在噪声的条件下（SNR = 6 dB），InversionNet 产生的反演结果明显不准确；这一局限性在应用于真实实验数据时尤为突出——InversionNet 无法保持其稳健性。相比之下， UFNO 方法在仿真与实验场景下均 consistently 保持了更优的反演质量。尽管 UFNO 模型的训练过程需要较高的计算成本（约 30 小时），但训练完成后的模型可实现高效的推理——仅需 49 秒即可处理 1,000 个样本，这相较于传统的 FWI 方法具有显著的提速优势，并支持基于 FMC 的超声波系统实现近实时成像。U- FNO 所具备的增强鲁棒性与泛化能力可归因于其双路径设计：可训练的核函数 R 在傅里叶空间中进行参数化，并采用截断的高频模态，用于捕捉全局频域特征；而 Unet 路径则用于恢复局部高频细节。这种协同设计使得模型能够高效处理复杂的数据模式及细微关联。此外，与传统的基于物理原理的 FWI 方法不同，U- FNO 无需使用初始速度模型，且可规避周期跳过问题。本研究针对计算波场成像领域的三大核心挑战——精度、效率与鲁棒性——特别是在数据仅存在于单侧边界条件下的不适定逆问题场景下进行了探讨。尽管本研究中 NDT 问题是主要的应用场景，但所提出的方法可推广至其他面临类似逆问题的计算成像领域，例如医学超声断层扫描、雷达成像及地震勘探。

尽管当前的数值计算结果与实验室实验取得了显著进展，但仍需承认其中存在若干固有局限性。

首先，当前的建模配置仅限于 1500–5800 m/s 的速度范围，验证工作主要针对嵌入固态基体介质中的充满水的缺陷进行。尽管这一场景在实际检测中具有相关性，但它并未涵盖更极端的阻抗对比情况（例如充满空气的缺陷），在这种情况下，较高的速度对比度会显著增加定量反演的难度。在这些情况下，更强的散射效应与模式转换效应要求采用更精确的建模方法——这可能需要求解弹性波方程以考虑模式转换效应，采用更精细的空间离散化方法来捕捉低速区域内的散射现象，以及运用额外的反演策略以缓解局部极小值问题并稳定收敛过程；这些措施不可避免地会增加计算成本，进而使反演过程变得更加复杂。其次，最核心的挑战在于监督学习范式下神经网络的泛化能力。尽管所提方法在训练数据分布范围内始终能够实现高保真度的重建，但在采集参数设置、材料特性或结构构型发生显著变化时，其性能可能会下降。这种对数据分布偏移的敏感性是监督式、数据驱动型反演方法所固有的。因此，尽管在已学习的参数空间内可预期获得稳健的反演结果，但将方法外推至截然不同的场景仍存在较大挑战。为缓解这些局限性，目前已提出若干潜在的应对策略。首先，

通过数学随机化及几何变换（例如对已知速度模型进行翻转、形变或裁剪）来增强训练数据集的多样性，或可提升模型的泛化能力；其次，可采用迁移学习技术，借助预训练知识来加速模型对新领域的适应；第三，通过基于控制波方程引导的无监督框架引入物理约束，或可降低对数据的依赖性[49,59]，但此举可能会削弱通过学习得到的逆算子所带来的优势（包括计算效率）。

目前，本研究仅限于采用超声相控阵技术进行二维反演分析。然而，由于采用了理想化的二维波传播模型及点源换能器，该方法的适用范围受限于三维（3D）成像场景。要将该方法拓展至三维场景，需对波物理过程进行更精确的建模——包括纵向模式与剪切模式之间的转换以及换能器的方向性分析——以减少图像失真。此外，三维成像涉及规模大得多的观测数据集，这对计算资源提出了较高要求。因此，采用先进的硬件设备和算法优化对于支持高效数据处理及实现高质量的三维重建至关重要。近期关于基于 FNO 的三维波传播建模的研究表明，神经算子在解决高维逆问题方面具有巨大潜力[60]。这些研究成果将为未来构建基于神经算子的框架提供指导，从而为各类应用场景提供更高效、更可扩展的超声成像解决方案。

## 6. 结论

综上所述，我们开发了一种用于超声波全波形数据直接反演的 U- FNO 框架。通过学习从 FMC 数据到 L 波速度场的非线性逆映射关系，该框架消除了在每次反演过程中进行重复正向波模拟的必要性，摆脱了对初始速度模型的依赖，并有效规避了循环跳过问题。在推断阶段，该方法比传统的 FWI 方法效率高得多。得益于这一高效的推理机制，经过训练的 U- FNO 模型可支持基于 FMC 的超声波系统实现近实时成像。与受限于局部感受野的卷积神经网络不同，U- FNO 利用傅里叶空间核参数化方法来捕捉全局波物理特征，从而能够对复杂的几何缺陷进行高保真度重建。数值模拟与实验验证表明， UFNO 在准确性和鲁棒性方面始终优于基于射线的 TFM 方法以及基于 FCN 的 InversionNet 方法。未来的工作将重点提升 U- FNO 框架的泛化能力，旨在将其适用范围扩展至更广泛的基于波的成像应用场景。

## CRediT作者贡献声明

**江璐：**撰写初稿、验证、软件开发、方法论设计、调研、数据管理、概念化。**刘丽辉：**撰写审阅与编辑、项目监督、资金筹措、形式化分析、概念化。**李轩：**资源支持、项目管理、形式化分析、数据管理。**王世军：**软件、资源、形式化分析。**汪艳春：**文稿撰写——审阅与编辑、验证、项目管理、资金筹措、形式化分析、概念化。

## 利益冲突声明

作者声明，其不存在任何已知的、可能对本论文所述研究产生影响的潜在财务利益冲突或个人关系。

## 致谢

本研究得到了国家自然科学基金（项目编号：12422415、12327807、12374434、52321002）以及上海市科技创新行动计划（项目编号：24TS1412200、24ZR1490900）的资助。

## 数据可用性

数据可根据需求提供。

## 参考文献

[1] Claerbout，F. Jon，《构建反射面映射的统一理论》，《地球物理学》第36卷（1971年），第467页，https://doi.org/10.1190/1.1440185。
[2] J.H. Chang，T.K. Song，《一种抑制超声波衍射的新型合成孔径聚焦方法》，《IEEE Trans. Ultrason. Ferroelectr. Freq. Control》第 58 卷（2011 年），第 327–337 页，https://doi.org/10.1109/tuffc.2011.1810。
[3] C. Holmes、B.W. Drinkwater、P.D.Wilcox，《超声波发射-接收阵列数据全矩阵的后处理在无损检测中的应用》，《 NDT & E International》第38卷（2005年），第701–711页，https://doi.org/10.1016/j.ndteint.2005.04.002。
[4] L. Sun，J. Wei，C. Peng，W. Hao，F. Teng，L. Fan，L. Zhang，Q. Sui，M. Jiang，《基于超声导波的概率诊断成像方法——结合单路径散射稀疏重构技术用于复合材料结构多损伤检测》，《机械系统与信号处理》第 223 卷（2025年），页码 111858，https://doi.org/10.1016/j.ymssp.2024.111858。
[5] Y. Bao，J.B. Jia，《声学层析成像系统中改进的飞行时间估计算法》，《IEEE仪器与测量汇刊》第69卷（2020年），第974–984页，https://doi.org/10.1109/tim.2019.2908704。
[6] P.R. Williamson，《射线层析成像中散射所致分辨率极限指南》，《地球物理学》第56卷（1991年），第202–207页，https://doi.org/10.1190/1.1443032。

[7] T. Alkhalifah，《全模型波数反演法：重点探讨适当的波数延拓方法》，《地球物理学》第 81 卷（2016 年），R89–R98，https://doi.org/10.1190/geo2015-0537.1。
[8] K. Ji、P. Zhao、C. Zhuo、H. Jin、M. Chen、J. Chen、S. Ye、J. Fu，《用于多层复合材料结构超声全矩阵成像的高效相移迁移法》，《机械系统与信号处理》第174卷（2022年），页码：109114，https://doi.org/10.1016/j.ymssp.2022.109114。
[9] H.R. Stolt，《基于傅里叶变换的迁移法》，《地球物理学》第43卷（1978年），第23–48页。
[10] K. Zhang、Z. Yin、Z.C. Li、Y.R. Chen：基于 Born/Rytov 近似的波动方程层析速度反演方法，《应用地球物理学》第 10 卷（2013 年），第 314–322 页，https://doi.org/10.1007/s11770-013-0385-1。
[11] E.V. Malyarenko，M.K. Hinders，《超声 Lamb 波衍射断层扫描法》，《Ultrasonics》第 39 卷（2001 年），第 269–281 页，https://doi.org/10.1016/s0041-624x(01)00055-5。
[12] A. Tarantola，《基于声学近似的地震反射数据反演》，《地球物理学》第49卷（1984年），第1259–1266页，https://doi.org/10.1190/1.1441754.
[13] J. Virieux，S. Operto，《勘探地球物理中全波形反演概述》，《地球物理》第74卷（2009年），WCC1–WCC26，https://doi.org/10.1190/1.3238367。
[14] M. Warner、A. Ratcliffe、T. Nangoo、J. Morgan、A. Umpleby、N. Shah、V. Vinje、I. ˇStekl、L. Guasch、C. Win、G. Conroy、A. Bertrand：《各向异性三维全波形反演》，《地球物理学》第 78 卷（2013 年），R59–R80，https://doi.org/10.1190/geo2012-0338.1。
[15] T. Alkhalifah、B.B. Sun、Z. Wu，《全模型波数反演：识别难以获取的中模型波数的信息源》，《地球物理学》第 83 卷（2018 年），R597–R610，https://doi.org/10.1190/geo2017-0775.1。
[16] J. Rao、J.Z. Yang、M. Ratassepp、Z. Fan，《基于全波形反演的超声断层扫描技术实现速度与密度的多参数重建》，《Ultrasonics》第101卷（2020年），https://doi.org/10.1016/j.ultras.2019.106004。
[17] J. Rao、M. Ratassepp、Z. Fan，《基于全波形反演的导波层析成像法》，《IEEE 《超声、铁电与频率控制》杂志》第 63 卷（2016 年），第 737–745 页，https://doi.org/10.1109/ TUFFC .2016.2536144。
[18] J.Z. He、J. Rao、J.D. Fleming、H.N.Gharti，L.T.、Nguyen，G. 与 Morrison，G.：《适用于耦合二维固-流介质中复杂结构的数值超声全波形反演方法（FWI）》，《智能材料与结构》第 30 卷（2021 年），https://doi.org/10.1088/1361-665X/ac0f44。
[19] M. Aktharuzzaman、S. Anwar、D. Borisov、J. He，《基于精确换能器建模的弹性材料表征实验性全波形反演方法》，《机械系统与信号处理》第 213 卷（2024 年），页码 111320，https://doi.org/10.1016/j.ymssp.2024.111320。
[20] T. Burchner、S. Schmid、L. Bergbreiter、E. Rank、S. Kollmannsberger、C.U. Grosse：《总聚焦法、反时偏移法与全波形反演法在超声成像中的定量比较》，《Ultrasonics》第155卷（2025年），页码107705，https://doi.org/10.1016/j.ultras.2025.107705。
[21] Y.Z. Lin，L.J. Huang，《基于改进全变差正则化方案的声波与弹性波形反演》，《国际地球物理杂志》第 200 卷（2015 年），第 489–502 页，https://doi.org/10.1093/gji/ggu393。
[22] G.C. Wang、S.Y. Yuan、S.X. Wang：《在 FWI 中检索低波数信息——一种高效的循环跳过解决方案》，《IEEE地球科学与远程感测快报》。《LGRS》第16卷（2019年），第1125–1129页，https://doi.org/10.1109/lgrs.2019.2892998。
[23] 吴X.Q.、李Y.B.、苏C.、李P.P.、林W.J.，《基于最优传输辅助的全波形反演方法在超声计算机断层扫描中用于软组织多参数成像》，《超声学》第147卷（2025年），https://doi.org/10.1016/j.ultras.2024.107505。
[24] 李鹏鹏、李永斌、苏超、董志远、林伟强：基于Sobolev空间范数正则化全波形反演的超声计算机断层扫描方法，《中国物理学报B辑》第34卷（2025年），https://doi.org/10.1088/1674-1056/adbbc0。
[25] F.S. Yang，J.W. Ma，《深度学习反演：下一代地震速度模型构建方法》，《地球物理》第 84 卷（2019 年），R585，https://doi.org/10.1190/geo2018-0249.1。
[26] V. Kazei、O. Ovcharenko、P. Plotnitskii、D. Peter、X. Zhang、T. Alkhalifah，《基于深度学习将完整地震波形映射为垂直速度剖面》，《地球物理学》第 86 卷（2021 年），R711–R721 页，https://doi.org/10.1190/geo2019-0473.1。
[27] Z.P. Zhang，Y.Z. Lin，《数据驱动的地震波形反演：鲁棒性与泛化性研究》，《IEEE地球科学与远程感测汇刊》第58卷（2020年），第6900–6913页，https://doi.org/10.1109/tgrs.2020.2977635.
[28] S. Feng、Y. Lin、B. Wohlberg，《基于现场数据的多尺度数据驱动地震全波形反演研究》，《IEEE地球科学与远程感测汇刊》第60卷（2022年），第1–14页，https://doi.org/10.1109/ TGRS .2021.3114101。
[29] Huang X.G.、Wang C.、Ye W.R.、Greenhalgh S.、Li Y.：《基于数据驱动的带环状残差U-Net方案用于全波形反演》，《IEEE地球科学与远程感测汇刊》第62卷（2024年），https://doi.org/10.1109/tgrs.2024.3436688。
[30] Y. Wu，Y.Z. Lin，《InversionNet：一种高效且具有 Accurate Data-Driven Full Waveform 特性的逆向计算方法》，《IEEE 计算机成像汇刊》第 6 卷（2020 年），第 419–433 页，https://doi.org/10.1109/tci.2019.2956866。
[31] S. Yang、T. Alkhalifah、Y. Ren、B. Liu、Y. Li、P. Jiang，《基于深度学习的测井信息辅助高分辨率波形反演》，《IEEE地球科学与远程感测快报》第20卷（2023年），第1–5页，https://doi.org/10.1109/ LGRS .2023.3234211。
[32] 苏敏、张迪、杨海清、杨阳，《基于数据驱动的全波形反演技术用于超声骨定量成像》，《神经计算与应用》第35卷（2023年），第25027–25043页，https://doi.org/10.1007/s00521-023-08464-6。
[33] L. Lozenski、H.C. Wang、F.Li，M. Anastasio，B. Wohlberg，Y.Z. Lin，U. Villa，《结合任务信息的全波形反演方法在超声计算机断层扫描中的应用》，《IEEE 计算机成像汇刊》第 10 卷（2024 年），第 69–82 页，https://doi.org/10.1109/tci.2024.3351529。
[34] J.H. Ren、J. Li、C. Liu、S.L. Chen、L. Liang、Y. Liu，《基于物理嵌入式神经网络的深度学习方法用于全波形超声脑成像》，《IEEE医学影像汇刊》第43卷（2024年），第2332–2346页，https://doi.org/10.1109/tmi.2024.3363144。
[35] J. Rao、F.S. Yang、H.D. Mo、S. Kollmannsberger、E. Rank：基于全卷积网络超声波反演方法对多层粘接复合材料缺陷进行定量重建，《声学与振动学报》第 542 卷（2023 年），https://doi.org/10.1016/j.jsv.2022.117418。
[36] L. Liu、W. Liu、D. Teng、Y. Xiang、F.-Z. Xuan：一种基于全矩阵捕获数据进行超分辨率超声相控阵成像的多尺度残差U-Net架构，《美国声学学会杂志》第154卷（2023年），第2044–2054页，https://doi.org/10.1121/10.0021171。
[37] V.N. Vapnik，《统计学习理论综述》，《IEEE 神经网络汇刊》第 10 卷（1999 年），第 988–999 页，https://doi.org/10.1109/72.788640.
[38] L. Lu、P. Jin、G. Pang、Z. Zhang、G.E. Karniadakis，《基于算子通用逼近定理的 DeepONet 用于学习非线性算子》，《自然·机器智能》（Nat. Mach. Intell.）第 3 卷（2021 年），第 218–229 页，https://doi.org/10.1038/s42256-021-00302-5。
[39] N. Kovachki、Z.Y. Li、B. Liu、K. Azizzadenesheli、K. Bhattacharya、A. Stuart、A. Anandkumar，《神经算子：学习函数空间之间的映射——在偏微分方程中的应用》，《机器学习研究杂志》第 24 卷（2023 年）。
[40] Z. Li、N. Kovachki、K. Azizzadenesheli、B. Liu、K. Bhattacharya、A. Stuart、A. Anandkumar，《用于参数化偏微分方程的傅里叶神经算子》，发表于（2020）arXiv:2010.08895。
[41] T. Kurth、S. Subramanian、P. Harrington、J. Pathak、M. Mardani、D. Hall、A. Miele、K. Kashinath、A. Anandkumar ——《FourCastNet：利用自适应傅里叶神经算子加速全球高分辨率天气预报》（2023年，瑞士达沃斯）。
[42] G.G. Wen、Z.Y. Li、Q.R. Long、K. Azizzadenesheli、A. Anandkumar、S.M. Benson：基于嵌套傅里叶神经算子的实时高分辨率二氧化碳地质封存预测——《能源与环境科学》。《16 (2023) 1732–1741》，https://doi.org/10.1039/d2ee04204e。

[43] L. Lu、X. Meng、S. Cai、Z. Mao、S. Goswami、Z. Zhang、G.E. Karniadakis：基于 FAIR 数据对两种神经算子（含实际扩展方案）进行全面且公正的比较，《计算方法与应用力学工程》第 393 卷（2022 年），页码 114778，https://doi.org/10.1016/j.cma.2022.114778。

[44] 钟明、闫志、田世峰：基于深度学习与傅里叶神经算子的非线性波动方程中数据驱动的参数化孤子-Rogon态跃迁研究，《理论物理通讯》第75卷（2023年），页码：025001，https://doi.org/10.1088/1572-9494/acab55。

[45] Q. Hao，T. Alkhalifah，《适用于具有垂直对称轴的横向各向同性介质的声学等波线方程》，《地球物理学》第 82 卷（2016 年），C9–C20 页，https://doi.org/10.1190/geo2016-0160.1。

[46] H.-M. Ren，S.-F. Tian，基于傅里叶神经算子方法求解耦非线性薛定谔方程组解的演化过程，Math. Comput. Simul 239 (2026) 1082–1096，https://doi.org/10.1016/j.matcom.2025.07.059。

[47] 朱明、冯思华、林永志、L.Lu，Fourier-DeepONet：基于傅里叶变换增强的深度算子网络用于全波形反演，提升其精度、泛化能力与鲁棒性，《计算方法与应用力学工程》第 416 卷（2023 年），https://doi.org/10.1016/j.cma.2023.116300。

[48] X. Huang，T. Alkhalifah，《基于神经算子的频域散射波场求解方法》，《国际地球物理杂志》第 241 卷（2025 年），第 1467–1478 页，https://doi.org/10.1093/gji/ggaf113。

[49] X. Huang、F. Wang、T. Alkhalifah，《基于预训练波场神经算子的物理信息波形反演》，《IEEE地球科学与远程感测汇刊》第 63 卷（2025 年），第 1–14 页，https://doi.org/10.1109/ TGRS .2025.3624025。

[50] E.J. Wang、J. Ba、Y. Liu，《基于时空域隐式有限差分法的声波方程建模》，《地球物理学报》第83卷（2018年），T175–T193页，https://doi.org/10.1190/geo2017-0546.1。

[51] A. Pinto，G. Leite，M. Pereira，H. Yviquel，S. Rigo，G. Araujo，《DeepWave：一款用于地球物理领域深度学习模型并行化的 Software Stack 》，载于：《2024年 IEEE 第36届国际计算机体系结构与高性能计算研讨会（SBAC -PAD）》，2024年，第 49–58 页IEEE 第36届国际计算机体系结构与高性能计算研讨会（SBAC -PAD），2024年，第 49–58 页。

[52] M. Alfarhan、M. Ravasi、F. Chen、T. Alkhalifah，《基于深度Hessian去模糊技术的鲁棒全波形反演》，《国际地球物理杂志》第240卷（2024年），第303–316页，https://doi.org/10.1093/gji/ggae378.

[53] G.G. Wen、Z.Y. Li、K. Azizzadenesheli、A. Anandkumar、S.M. Benson、U- FNO ——一种基于增强型傅里叶神经算子的流场深度学习模型，《Adv. Water Resour.》第163卷（2022年），https://doi.org/10.1016/j.advwatres.2022.104180。

[54] W. Zhou、A.C. Bovik、H.R. Sheikh、E.P. Simoncelli，《图像质量评估：从误差可见度到结构相似性》，《IEEE 信号与图像处理汇刊》第 13 卷（2004 年），第 600–612 页，https://doi.org/10.1109/TIP.2003.819861。

[55] G. Cohen、S. Afshar、J. Tapson、A. van Schaik，《 EMNIST：将 MNIST 扩展至手写字母》，载于（2017）arXiv:1702.05373。

[56] J. Liu、H.L. Zhou、T. Ouyang、Q.G. Liu、Y.H. Wang，《基于物理模型的深度展开网络用于求解非线性逆散射问题》，《IEEE Trans. Antennas Propag.》第 70 卷（2022 年），第 1236–1249 页，https://doi.org/10.1109/tap.2021.3111281。

[57] J.K. Tong、J. Li、M. Lin、S.L. Chen、G. A. Chu、L.L. Lv、P.F. Zhang、Z.F. Tang、Y. Liu，《基于剪切水平波与深度卷积下降全波形反演的定量导波成像》，《NDT & E International》第145卷（2024年），https://doi.org/10.1016/j.ndteint.2024.103141.

[58] B. Guo、Y. Zhang、Z. Yang、D. Cui、F. He、J. Li、Z. Wang、X. Lin、J. Wang，《Hastelloy X 超级合金在定向能沉积增材制造过程中的裂纹形成机理》，《增材制造》第 55 卷（2022 年），https://doi.org/10.1016/j.addma.2022.102792。

[59] Z. Xiao、J. Rao、S. Eisentr¨ager、K.-V. Yuen、S. A. Hadigheh，《基于生成对抗网络的高密度聚乙烯结构超声全波形反演方法》，《机械系统与信号处理》第224卷（2025年），页码112160，https://doi.org/10.1016/j.ymssp.2024.112160。

[60] F. Lehmann、F. Gatti、M. Bertin、D. Clouteau，《基于因子化傅里叶神经算子的三维弹性波传播方法（F- FNO）》，《计算方法与应用力学工程》第 420 卷（2024 年），https://doi.org/10.1016/j.cma.2023.116718。